

数理统计期末练习题

Chapter 1

每章练习题

1.1 充分统计量

费希尔-内曼分解定理/因子分解定理

求解充分统计量的核心工具是因子分解定理。求解充分统计量的“四步法”总结如下：

第一步：写出联合分布

首先，根据题目给出的总体分布，写出样本 x_1, x_2, \dots, x_n 的联合分布。

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

注：如果分布的取值范围依赖于参数 θ （比如均匀分布 $U(0, \theta)$ ），一定要使用示性函数 $I(\cdot)$ 把范围写进表达式里。

第二步：尝试“拆分”表达式

观察写出的 $L(\theta; \mathbf{x})$ ，尝试把它拆成两个部分的乘积： $L(\theta; \mathbf{x}) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$

$g(T(\mathbf{x}), \theta)$ 部分：这一部分是关于参数 θ 和随机变量 x 的函数， $T(\mathbf{x})$ 是仅关于随机变量的函数。

$h(\mathbf{x})$ 部分：这一部分与参数 θ 无关，是只含随机变量 x_i 的函数。

第三步：识别 $T(\mathbf{x})$

在 g 部分中，那个把所有样本信息“打包”起来的表达式 $T(\mathbf{x})$ ，就是我们要找的充分统计量。

第四步：给出结论，写出 $h(x), g(T(x), \theta), T(x)$

问题 1. 设 x_1, x_2, \dots, x_n 是来自几何分布总体

$$P\{X = x\} = p(1 - p)^{x-1}, \quad x = 1, 2, \dots$$

的简单样本，其中 $0 < p < 1$ 。试求参数 p 的充分统计量。

解析：我们利用因子分解定理。首先写出样本的联合分布。

1 样本的联合分布为:

$$L(p) = \prod_{i=1}^n p(1-p)^{x_i-1} = p^n(1-p)^{\sum_{i=1}^n x_i - n}$$

2 根据因子分解定理, 如果似然函数可以写成 $L(p) = g(T(x), p) \cdot h(x)$ 的形式, 则 $T(x)$ 是充分统计量。在本题中, 我们可以令:

$$g(T(x), p) = p^n(1-p)^{\sum x_i - n}, \quad h(x_1, \dots, x_n) = 1$$

其中 $T(x_1, \dots, x_n) = \sum_{i=1}^n x_i$ 。

结论: $\sum_{i=1}^n x_i$ 是参数 p 的充分统计量 (同样地, 样本均值 \bar{x} 也是充分统计量)。

问题 2. 设 x_1, x_2, \dots, x_n 是来自离散总体 X 的样本, X 的分布列为

$$P\{X = v_i\} = p_i, \quad i = 1, 2, \dots, m$$

其中 p_1, p_2, \dots, p_m 是参数。用 n_i 表示 x_1, x_2, \dots, x_n 中等于 v_i 的个数, 证明: (n_1, n_2, \dots, n_m) 是充分统计量。

证明: 1 样本的联合分布可以表示为:

$$L(x_1, \dots, x_n; p_1, \dots, p_m) = \prod_{j=1}^n P(X = x_j)$$

2 由于在 n 个观测值中, v_1 出现了 n_1 次, v_2 出现了 n_2 次, \dots , v_m 出现了 n_m 次, 因此联合概率可以写成:

$$L = p_1^{n_1} p_2^{n_2} \cdots p_m^{n_m}$$

显然, 这个表达式只依赖于统计量 $T = (n_1, n_2, \dots, n_m)$ 和参数 (p_1, \dots, p_m) 。

3 令 $h(x_1, \dots, x_n) = 1$, 根据因子分解定理, $T(x_1, \dots, x_n) = (n_1, n_2, \dots, n_m)$ 是参数的充分统计量。

问题 3. 设 x_1, x_2, \dots, x_n 是来自均匀分布 $U(\theta, 2\theta)$ ($\theta > 0$) 总体 X 的样本, 求充分统计量。

解析: 对于均匀分布, 关键在于使用指示函数 $I(\cdot)$ 来表示范围。

1 总体密度函数为: $f(x; \theta) = \frac{1}{2\theta - \theta} = \frac{1}{\theta}, \quad \theta < x_i < 2\theta$ 。

2 样本的联合密度函数为:

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} I_{(\theta, 2\theta)}(x_i) = \frac{1}{\theta^n} I(\theta < x_i < 2\theta) = \frac{1}{\theta^n} I(\theta < x_{(1)}) I(x_{(n)} < 2\theta)$$

结论: 充分统计量为 $T(x_1, \dots, x_n) = (x_{(1)}, x_{(n)})$ 。

问题 4. 设总体 X 的分布是双参数指数分布, 其密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\sigma} \exp \left\{ -\frac{x - \mu}{\sigma} \right\}, & x > \mu \\ 0, & x \leq \mu \end{cases}$$

其中 $\sigma (\sigma > 0)$ 及 μ 是常数。 x_1, x_2, \dots, x_n 是来自总体 X 的样本。

1. 证明：当 σ 已知， μ 未知时， $x_{(1)} = \min_{1 \leq i \leq n} \{x_i\}$ 是 μ 的充分统计量；
2. 当 μ 已知， σ 未知时，求 σ 的充分统计量。
3. 求参数 $\theta = (\mu, \sigma)$ 的充分统计量。

【解析】

准备工作：首先，我们要写出样本 x_1, \dots, x_n 的联合分布。注意，这里有一个隐含的条件 $x_i > \mu$ ，我们用指示函数 $I(x > \mu)$ 来表示。

$$L(x_1, \dots, x_n; \mu, \sigma) = \prod_{i=1}^n \frac{1}{\sigma} \exp \left\{ -\frac{x_i - \mu}{\sigma} \right\} I(x_i > \mu) = \frac{1}{\sigma^n} \exp \left\{ -\frac{\sum_{i=1}^n x_i + n\mu}{\sigma} \right\} I(x_{(1)} > \mu)$$

1 σ 已知，证明 $x_{(1)}$ 是 μ 的充分统计量

证明：当 σ 已知时，参数只有 μ 。我们将上面的 L 进行整理，尝试分离出只含 x 的部分和含 μ 的部分：

$$L(\mu) = \underbrace{\exp \left\{ \frac{n\mu}{\sigma} \right\} I(x_{(1)} > \mu)}_{g(x_{(1)}; \mu)} \cdot \underbrace{\frac{1}{\sigma^n} \exp \left\{ -\frac{\sum x_i}{\sigma} \right\}}_{h(x_1, \dots, x_n)}$$

根据分解定理， $x_{(1)}$ 是 μ 的充分统计量。

2 μ 已知，求 σ 的充分统计量

当 μ 已知时，参数只有 σ 。我们重新观察联合密度：

$$L(\sigma) = \frac{1}{\sigma^n} \exp \left\{ -\frac{\sum (x_i - \mu)}{\sigma} \right\} I(x_{(1)} > \mu)$$

由于 μ 已知，指示函数 $I(x_{(1)} > \mu)$ 的值要么是 0 要么是 1，它不依赖于未知参数 σ ，可以归入 $h(x)$ 。剩下的部分 $\frac{1}{\sigma^n} \exp \left\{ -\frac{\sum (x_i - \mu)}{\sigma} \right\}$ 中，样本 x_i 是通过 $\sum_{i=1}^n (x_i - \mu)$ 这个整体与 σ 发生关系的。

因此， σ 的充分统计量为：

$$T = \sum_{i=1}^n (x_i - \mu)$$

(注：由于 μ 已知，写成 $\sum x_i$ 或样本均值 \bar{x} 也是可以的)。

3 求参数 $\theta = (\mu, \sigma)$ 的充分统计量

解：现在 μ 和 σ 都是未知的。我们需要找到一组统计量，使得整个似然函数能被分解。回到联合密度函数：

$$L(\mu, \sigma) = \frac{1}{\sigma^n} \exp \left\{ \frac{n\mu}{\sigma} \right\} \exp \left\{ -\frac{\sum x_i}{\sigma} \right\} I(x_{(1)} > \mu)$$

观察发现，为了涵盖所有的未知参数，我们需要同时知道 $x_{(1)}$ 和 $\sum x_i$ 。

我们可以令：

$$T = (x_{(1)}, \sum_{i=1}^n x_i)$$

此时：

$$g(T; \mu, \sigma) = \frac{1}{\sigma^n} \exp \left\{ \frac{n\mu - T_2}{\sigma} \right\} I(T_1 > \mu)$$

$$h(x) = 1$$

根据分解定理，联合充分统计量为：

$$T = (x_{(1)}, \sum_{i=1}^n x_i)$$

或者也可以写成 $(x_{(1)}, \bar{x})$ 。

1.2 参数估计

1.2.1 频率替换估计法

这类题目总结为以下三个固定步骤：

- 1 找概率模型：根据题目给出的分布（如正态分布、指数分布），计算出某个特定事件（如 $X \leq 0$ 或 $X < 2$ ）发生的理论概率 P 。这个 P 通常是关于待求参数的函数。
- 2 找样本频率：题目通常会告诉你“ n 个样本中有 m 个满足条件”，那么样本频率就是 m/n 。
- 3 解方程：令理论概率 = 样本频率，这就像是我们在用现实中观察到的比例去“倒推”模型中的参数。

问题 5. 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, 1)$ 的简单样本，在这 n 个样本观测值中有 m 个取值不大于零，求 μ 的频率替换估计。

【解析】

设总体为 $X \sim N(\mu, 1)$ 。

1 确定理论概率：考虑事件 $A = \{X \leq 0\}$ 。我们要计算 $P(X \leq 0)$ ，但我们手头只有标准正态分布表（即 $N(0, 1)$ 的 Φ 函数）。通过公式 $Z = \frac{X - E(X)}{\sqrt{Var(X)}}$ ，我们将 X 转化为标准正态分布，该事件发生的理论概率 p 为：

$$p = P(X \leq 0) = P\left(\frac{X - \mu}{1} \leq \frac{0 - \mu}{1}\right) = \Phi(-\mu)$$

其中 $\Phi(\cdot)$ 是标准正态分布的累积分布函数。

2 确定样本频率：根据题意，在 n 个样本观测值中有 m 个取值不大于零，因此事件 A 发生的样本频率为：

$$\hat{p} = \frac{m}{n}$$

3 频率替换建立方程：利用频率替换原理，令理论概率等于样本频率：

$$\Phi(-\hat{\mu}) = \frac{m}{n}$$

4 解方程求估计量：对等式两边同时作用标准正态分布函数的反函数 Φ^{-1} ，得：

$$-\hat{\mu} = \Phi^{-1}\left(\frac{m}{n}\right)$$

即：

$$\hat{\mu} = -\Phi^{-1}\left(\frac{m}{n}\right)$$

问题 6 (★). 设总体 X 服从两点分布 $B(1, p)$ ，其中参数 $p \in (0, 1)$ ， x_1, x_2, \dots, x_n 是来自总体 X 的简单样本。(1) 求 $q(p) = \text{Var}_p(\bar{x})$ ；(2) 求 $q(p)$ 的频率替换估计。

【解析】

第一问：计算理论方差

已知 $X \sim B(1, p)$ ，则总体的期望 $E(X) = p$ ，方差 $\text{Var}(X) = p(1-p)$ 。样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ，其中 x_1, x_2, \dots, x_n 是独立同分布于 X 的样本。根据方差的性质：对于独立随机变量 x_1, \dots, x_n ，有

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i)$$

由于每个 $x_i \sim B(1, p)$ ，故 $\text{Var}(x_i) = p(1-p)$ ，代入得：

$$\text{Var}_p(\bar{x}) = \frac{1}{n^2} \cdot n \cdot p(1-p) = \frac{p(1-p)}{n}$$

因此， $q(p) = \boxed{\frac{p(1-p)}{n}}$ 。

第二问：频率替换估计

在两点分布中，参数 p 的含义是事件 $\{X = 1\}$ 发生的概率。根据频率替换原则，我们用样本中事件发生的频率来估计概率。对于 $B(1, p)$ ，因为 x_i 只取 0 或 1，**样本均值 \bar{x} 恰好就是事件 $\{X = 1\}$ 出现的频率**。因此，频率估计 $\hat{p} = \bar{x}$ 。将 $\hat{p} = \bar{x}$ 代入 $q(p)$ 的表达式中，得到 $q(p)$ 的频率替换估计量为：

$$\hat{q}(p) = \frac{\bar{x}(1-\bar{x})}{n}$$

问题 7. 设总体 X 服从参数为 $\lambda (\lambda > 0)$ 的**指数分布**，其密度函数为

$$f(x; \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

x_1, x_2, \dots, x_n 是来自总体 X 的简单样本，且这 n 个观察值中有 m 个取值小于 2，求 λ 的频率替换估计。

【解析】**第一步：计算理论概率**

指数分布是连续型随机变量， X 的取值为连续非负实数 $([0, +\infty))$ 。设事件 $A = \{X < 2\}$ 。计算 X 落在该区间的概率：

$$P(A) = \int_0^2 \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^2 = 1 - e^{-2\lambda}$$

第二步：建立等式

样本中事件 A （取值小于 2）发生的频率为 $\frac{m}{n}$ 。令理论概率等于样本频率：

$$1 - e^{-2\lambda} = \frac{m}{n}$$

第三步：解出参数

整理等式：

$$e^{-2\lambda} = 1 - \frac{m}{n} = \frac{n - m}{n}$$

两边取自然对数：

$$-2\lambda = \ln\left(1 - \frac{m}{n}\right)$$

解得 λ 的频率替换估计量为：

$$\hat{\lambda} = -\frac{1}{2} \ln\left(1 - \frac{m}{n}\right)$$

1.2.2 矩估计和极大似然估计

问题 8. 设总体 X 的概率密度函数为

$$f(x, \theta) = \begin{cases} \frac{1}{2\theta}, & 0 \leq x < \theta \\ \frac{1}{2(1-\theta)}, & \theta \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$

其中参数 $\theta \in (0, 1)$ ， x_1, x_2, \dots, x_n 是来自总体 X 的简单样本，求参数 θ 的矩估计 $\hat{\theta}$ 。

【解析】

解题思路：矩估计法的核心是利用“样本矩等于总体矩”。这里只有一个未知参数 θ ，我们只需要用到样本一阶原点矩，即期望 $E(X)$ 。

1 计算总体的期望 $E(X)$: 根据期望的定义 $E(X) = \int_{-\infty}^{+\infty} xf(x, \theta)dx$:

$$\begin{aligned} E(X) &= \int_0^\theta x \cdot \frac{1}{2\theta} dx + \int_\theta^1 x \cdot \frac{1}{2(1-\theta)} dx \\ &= \frac{1}{2\theta} \left[\frac{1}{2}x^2 \right]_0^\theta + \frac{1}{2(1-\theta)} \left[\frac{1}{2}x^2 \right]_\theta^1 \\ &= \frac{1}{2\theta} \cdot \frac{\theta^2}{2} + \frac{1}{2(1-\theta)} \cdot \frac{1-\theta^2}{2} \\ &= \frac{\theta}{4} + \frac{(1-\theta)(1+\theta)}{4(1-\theta)} \\ &= \frac{\theta}{4} + \frac{1+\theta}{4} = \frac{2\theta+1}{4} \end{aligned}$$

2 样本矩等于总体矩, $E(X) = \bar{x}$, 反解出 θ :

$$2\theta + 1 = 4\bar{x} \implies 2\theta = 4\bar{x} - 1 \implies \theta = 2\bar{x} - \frac{1}{2}$$

结论: 参数 θ 的矩估计量为 $\hat{\theta} = 2\bar{x} - \frac{1}{2}$ 。

问题 9. 设总体 X 服从对数正态分布 $\text{LN}(\mu, \sigma^2)$, 其密度函数为

$$f(x; \mu, \sigma^2) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma x} \exp\left\{-\frac{(\ln x - \mu)^2}{2\sigma^2}\right\}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中 μ 和 σ^2 均未知, x_1, x_2, \dots, x_n 是来自总体 X 的简单样本, 求 μ 及 σ^2 的矩估计和极大似然估计。

【解析】

这道题目是对数正态分布参数估计的经典题型。对数正态分布与正态分布有着紧密的联系: 如果 X 服从对数正态分布, 那么 $Y = \ln X$ 就服从正态分布。考试现场推导不太现实, 所以给出如下通用结论, 当做结论记:

$$E(X^k) = \int_0^{+\infty} x^k f(x; \mu, \sigma^2) dx = \exp\left\{\mu k + \frac{1}{2}\sigma^2 k^2\right\}$$

所以, 在解答之前, 我们有对数正态分布 $X \sim \text{LN}(\mu, \sigma^2)$ 的前两阶原点矩: $E(X) = \exp\{\mu + \frac{1}{2}\sigma^2\}$, $E(X^2) = \exp\{2\mu + 2\sigma^2\}$ 。

一、矩估计

矩估计法的核心是令总体矩等于样本矩。由于有两个未知参数, 我们需要用到样本一阶和二阶原点矩。

1 建立方程组: 设总体的一阶原点矩为 $E(X)$, 二阶原点矩为 $E(X^2)$ 。样本的一阶原点矩为 $\bar{x} = \frac{1}{n} \sum x_i$, 二阶原点矩为 $A_2 = \frac{1}{n} \sum x_i^2$ 。我们有:

$$\begin{cases} e^{\mu + \frac{1}{2}\sigma^2} = \bar{x} & (1) \\ e^{2\mu + 2\sigma^2} = A_2 & (2) \end{cases}$$

2 求解方程组：对两边取自然对数：

$$\begin{cases} \mu + \frac{1}{2}\sigma^2 = \ln \bar{x} & (3) \\ 2\mu + 2\sigma^2 = \ln A_2 & (4) \end{cases}$$

解得：

$$\hat{\sigma}^2 = \ln A_2 - 2 \ln \bar{x} = \ln \left(\frac{A_2}{\bar{x}^2} \right)$$

$$\hat{\mu} = \ln \bar{x} - \frac{1}{2} \ln \left(\frac{A_2}{\bar{x}^2} \right) = \ln \bar{x} - \ln \sqrt{\frac{A_2}{\bar{x}^2}} = \ln \left(\frac{\bar{x}^2}{\sqrt{A_2}} \right)$$

结论： μ 和 σ^2 的矩估计量分别为：

$$\hat{\mu} = 2 \ln \bar{x} - \frac{1}{2} \ln \left(\frac{1}{n} \sum x_i^2 \right), \quad \hat{\sigma}^2 = \ln \left(\frac{1}{n} \sum x_i^2 \right) - 2 \ln \bar{x}$$

二、极大似然估计

1 写出似然函数：

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \left(\prod_{i=1}^n \frac{1}{x_i} \right) \exp \left\{ - \sum_{i=1}^n \frac{(\ln x_i - \mu)^2}{2\sigma^2} \right\}$$

2 取对数似然函数：

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \sum_{i=1}^n \ln x_i - \frac{1}{2\sigma^2} \sum_{i=1}^n (\ln x_i - \mu)^2$$

3 求偏导并令其为零：

对 μ 求**偏导**：

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (\ln x_i - \mu) = 0 \implies \sum_{i=1}^n \ln x_i - n\mu = 0$$

解得： $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \ln x_i$ 。

对 σ^2 求**偏导**：

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (\ln x_i - \mu)^2 = 0$$

将 $\hat{\mu}$ 代入，解得： $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (\ln x_i - \hat{\mu})^2$ 。

结论： μ 和 σ^2 的极大似然估计量分别为：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \ln x_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (\ln x_i - \hat{\mu})^2$$

问题 10. 设总体 X 的分布函数为

$$F(x; \beta) = \begin{cases} 1 - \frac{1}{x^\beta}, & x > 1 \\ 0, & x \leq 1 \end{cases}$$

其中 $\beta (\beta > 1)$ 是未知参数, x_1, x_2, \dots, x_n 是来自总体 X 的简单样本. 试求 β 的矩估计和极大似然估计.

【解析】

首先要看清题目给的是分布函数, 分布函数与概率密度函数关系总结如下:

分布函数 $F(x)$: 是“到此为止的总概率”, 范围在 0 到 1 之间, 是单调不减的.

概率密度 $f(x)$: 是“概率在某处的分布强度”, 它本身不是概率, 它在某个区间上的积分才是概率.

关系: $F(x) \xrightarrow{\text{求导}} f(x); f(x) \xrightarrow{\text{积分}} F(x)$.

因此, 在进行估计之前, 我们先求出总体的概率密度函数 $f(x; \beta)$. 对分布函数 $F(x; \beta)$ 求导得:

$$f(x; \beta) = \frac{d}{dx} F(x; \beta) = \begin{cases} \beta x^{-(\beta+1)}, & x > 1 \\ 0, & \text{其他} \end{cases}$$

1 矩估计法

第一步: 计算总体均值 (一阶原点矩)

$$E(X) = \int_1^{+\infty} x \cdot f(x; \beta) dx = \int_1^{+\infty} x \cdot \beta x^{-\beta-1} dx = \beta \int_1^{+\infty} x^{-\beta} dx$$

由于题目给定 $\beta > 1$, 积分收敛:

$$E(X) = \beta \left[\frac{x^{-\beta+1}}{-\beta+1} \right]_1^{+\infty} = \beta \left(0 - \frac{1}{1-\beta} \right) = \frac{\beta}{\beta-1}$$

第二步: 令样本均值等于总体均值, 令 $E(X) = \bar{x}$, 即:

$$\frac{\beta}{\beta-1} = \bar{x}$$

第三步: 解出 β

$$\beta = \bar{x}(\beta-1) \implies \beta = \bar{x}\beta - \bar{x} \implies \bar{x} = \beta(\bar{x}-1)$$

解得 β 的矩估计量为:

$$\hat{\beta}_M = \frac{\bar{x}}{\bar{x}-1}$$

2 极大似然估计法

第一步: 写出似然函数 $L(\beta)$

$$L(\beta) = \prod_{i=1}^n f(x_i; \beta) = \prod_{i=1}^n \beta x_i^{-(\beta+1)} = \boxed{\beta^n \left(\prod_{i=1}^n x_i \right)^{-(\beta+1)}}$$

第二步：取对数似然函数 $\ln L(\beta)$ ，为了方便求导，我们取自然对数：

$$\ln L(\beta) = \ln \left[\beta^n \left(\prod_{i=1}^n x_i \right)^{-(\beta+1)} \right] = n \ln \beta - (\beta + 1) \sum_{i=1}^n \ln x_i$$

第三步：对 β 求导并令其为 0

$$\frac{d}{d\beta} \ln L(\beta) = \frac{n}{\beta} - \sum_{i=1}^n \ln x_i = 0$$

第四步：解出 β

$$\frac{n}{\beta} = \sum_{i=1}^n \ln x_i \implies \hat{\beta}_L = \frac{n}{\sum_{i=1}^n \ln x_i}$$

由于 β 的二阶导数小于 0，该点确实是极大值点。所以 β 的极大似然估计量为：

$$\hat{\beta}_L = \frac{n}{\sum_{i=1}^n \ln x_i}$$

问题 11. 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本， μ 和 σ^2 均为未知，试求 $P\{X \leq t\}$ 的极大似然估计。

【解析】

解题思路：本题考察极大似然估计的不变性原理。如果 $\hat{\theta}$ 是 θ 的极大似然估计，那么对于任何函数 $g(\theta)$ ， $g(\hat{\theta})$ 就是 $g(\theta)$ 的极大似然估计。

1 确定参数的极大似然估计：对于正态总体 $N(\mu, \sigma^2)$ ，我们已知其参数的极大似然估计分别为：

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

2 写出待求目标的表达式：令 $g(\mu, \sigma^2) = P\{X \leq t\}$ 。由于 $X \sim N(\mu, \sigma^2)$ ，进行标准化处理：

$$P\{X \leq t\} = P\left\{ \frac{X - \mu}{\sigma} \leq \frac{t - \mu}{\sigma} \right\} = \Phi\left(\frac{t - \mu}{\sigma}\right)$$

其中 $\Phi(\cdot)$ 是标准正态分布的累积分布函数。

3 利用不变性原理：将 $\hat{\mu}$ 和 $\hat{\sigma}$ 代入上式即可得到 $P\{X \leq t\}$ 的极大似然估计：

$$\hat{P}\{X \leq t\} = \Phi\left(\frac{t - \bar{x}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}}\right)$$

问题 12 (离散型随机变量极大似然估计). 设总体 X 的概率分布列为

X	0	1	2	3
p	θ^2	$2\theta(1-\theta)$	θ^2	$1-2\theta$

其中 $\theta \left(0 < \theta < \frac{1}{2}\right)$ 是未知参数，试求样本值为 3, 1, 3, 0, 3, 1, 2, 3 时 θ 的极大似然估计

【解析】

这道题目是离散型随机变量的极大似然估计问题。处理这类题目的关键在于：先统计样本中各个数值出现的频数，再根据概率分布列写出似然函数。

第一步：统计样本频数

$x = 0$ 出现了 1 次； $x = 1$ 出现了 2 次； $x = 2$ 出现了 1 次； $x = 3$ 出现了 4 次。样本总数 $n = 1 + 2 + 1 + 4 = 8$ 。

第二步：写出似然函数 $L(\theta)$

根据离散型随机变量极大似然估计的定义，似然函数为各样本值对应概率的乘积：

$$\begin{aligned} L(\theta) &= P(X=0)^1 \cdot P(X=1)^2 \cdot P(X=2)^1 \cdot P(X=3)^4 \\ &= (\theta^2)^1 \cdot [2\theta(1-\theta)]^2 \cdot (\theta^2)^1 \cdot (1-2\theta)^4 \\ &= \theta^2 \cdot 4\theta^2(1-\theta)^2 \cdot \theta^2 \cdot (1-2\theta)^4 \\ &= 4\theta^6(1-\theta)^2(1-2\theta)^4 \end{aligned}$$

第三步：取对数似然函数 $\ln L(\theta)$

$$\ln L(\theta) = \ln 4 + 6 \ln \theta + 2 \ln(1-\theta) + 4 \ln(1-2\theta)$$

第四步：对 θ 求导并解似然方程

$$\frac{d}{d\theta} \ln L(\theta) = \frac{6}{\theta} - \frac{2}{1-\theta} - \frac{4 \cdot 2}{1-2\theta} = \frac{6}{\theta} - \frac{2}{1-\theta} - \frac{8}{1-2\theta}$$

令导数为 0：

$$\frac{6}{\theta} - \frac{2}{1-\theta} - \frac{8}{1-2\theta} = 0$$

化简得：

$$12\theta^2 - 14\theta + 3 = 0$$

第五步：确定估计值，利用求根公式解方程：

$$\theta = \frac{14 \pm \sqrt{14^2 - 4 \times 12 \times 3}}{2 \times 12} = \frac{7 \pm \sqrt{13}}{12}$$

判断是否符合约束条件 $0 < \theta < \frac{1}{2}$ ：

$\sqrt{13} \approx 3.61$, $\theta_1 = \frac{7+3.61}{12} \approx 0.88$ (不符合 $\theta < 0.5$, 舍去), $\theta_2 = \frac{7-3.61}{12} \approx 0.28$ (符合 $0 < \theta < 0.5$)

因此， θ 的极大似然估计量为：

$$\hat{\theta} = \frac{7 - \sqrt{13}}{12}$$

问题 13. 设 X 为某电子元件的失效时间，其密度函数为

$$f(x; \alpha, \beta) = \begin{cases} \beta e^{-\beta(x-\alpha)}, & x > \alpha > 0 \\ 0, & x \leq \alpha \end{cases}$$

其中 $\beta > 0$ 。抽取 n 个该电子元件，独立地进行测试，失效时间分别为 x_1, x_2, \dots, x_n 。
 (1) 当 α 已知时，求 β 的极大似然估计；(2) 当 β 已知时，求 α 的极大似然估计；(3) 当 α 和 β 都是未知参数时，求 α 和 β 的极大似然估计。

【解析】

解题思路：极大似然估计的第一步是写出似然函数 L 。注意密度函数中的范围限制 $x > \alpha$ ，这在求 α 的估计时至关重要。

似然函数：

$$L(\alpha, \beta) = \prod_{i=1}^n f(x_i; \alpha, \beta) = \begin{cases} \beta^n \exp\{-\beta \sum_{i=1}^n (x_i - \alpha)\}, & x_{(1)} > \alpha > 0 \\ 0, & \text{其他} \end{cases}$$

(1) α 已知，求 β ：

取对数似然函数： $\ln L = n \ln \beta - \beta \sum_{i=1}^n (x_i - \alpha)$ 。对 β 求导并令其为 0：

$$\frac{d \ln L}{d \beta} = \frac{n}{\beta} - \sum_{i=1}^n (x_i - \alpha) = 0 \implies \hat{\beta} = \frac{n}{\sum_{i=1}^n (x_i - \alpha)}$$

(2) β 已知，求 α ：

观察 $L(\alpha, \beta) = \beta^n e^{-\beta \sum x_i} e^{n\beta\alpha}$ 。因为 $\beta > 0$ ，所以 L 是关于 α 的增函数。为了使 L 最大， α 应该尽可能大。但受到条件 $x_{(1)} > \alpha$ 的限制， α 不能超过样本中的最小值。故 $\hat{\alpha} = x_{(1)}$ 。

(3) α, β 均未知：根据 (2)，无论 β 取何值，使 L 最大的 α 总是 $\hat{\alpha} = x_{(1)}$ 。将 $\hat{\alpha}$ 代入 (1) 的结果中，得到：

$$\hat{\alpha} = x_{(1)}, \quad \hat{\beta} = \frac{n}{\sum_{i=1}^n (x_i - x_{(1)})}$$

问题 14. 设总体 X 的概率密度函数为

$$f(x; \theta) = \begin{cases} \theta, & 0 \leq x < 1 \\ 1 - \theta, & 1 \leq x \leq 2 \\ 0, & \text{其他} \end{cases}$$

其中 $\theta (0 < \theta < 1)$ 是未知参数， x_1, x_2, \dots, x_n 是来自总体 X 的简单样本。求参数 θ 的极大似然估计 $\hat{\theta}$ 。

【解析】

解题思路：这是一个离散型思维的连续分布问题。我们需要统计样本落入不同区间的个数。

1 统计样本分布：设样本中有 k 个观测值落入区间 $[0, 1)$ ，其余 $n - k$ 个观测值落入区间 $[1, 2]$ 。这里 $k = \sum_{i=1}^n I(0 \leq x_i < 1)$

2 写出似然函数:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \theta^k (1 - \theta)^{n-k}$$

3 取对数并求导: $\ln L = k \ln \theta + (n - k) \ln(1 - \theta)$

$$\frac{d \ln L}{d\theta} = \frac{k}{\theta} - \frac{n - k}{1 - \theta} = 0$$

$$k(1 - \theta) = (n - k)\theta \implies k - k\theta = n\theta - k\theta \implies n\theta = k$$

4 结论: $\hat{\theta} = \frac{k}{n}$, 即样本落入 $[0, 1)$ 区间的频率。

问题 15 (参数空间有限制条件). 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, μ 和 σ^2 都是未知参数, 且 $\mu \leq \mu_0$, 其中 μ_0 是已知常数. 求 μ 和 σ^2 的极大似然估计。

【解析】

解题思路: 先求出无约束下的极值点, 再判断这个点是否在限制范围内; 如果不在, 则根据函数的单调性在边界上寻找最值。

第一步: 写出似然函数 $L(\mu, \sigma^2)$

由于样本相互独立, 似然函数等于各样本概率密度函数的乘积:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

整理得:

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

第二步: 写出对数似然函数 $\ln L(\mu, \sigma^2)$, 取对数以便于求导计算:

$$\ell(\mu, \sigma^2) = \ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

第三步: 分析无约束情况下的极值点, 如果不考虑约束条件 $\mu \leq \mu_0$, 我们对 μ 和 σ^2 分别求偏导并令其为 0:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu}_{un} = \bar{x}$$

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \implies \hat{\sigma}_{un}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

这说明, 对数似然函数在 $\mu = \bar{x}$ 处取得关于 μ 的全局最大值。

第四步: 结合约束条件 $\mu \leq \mu_0$ 进行讨论, 我们需要在区域 $\mu \in (-\infty, \mu_0]$ 上寻找使 $\ell(\mu, \sigma^2)$ 最大的参数。

情况 1: 当 $\bar{x} \leq \mu_0$, 此时, 无约束的最大值点 \bar{x} 已经落在限制区域内。因此, μ 的极大似然估计就是样本均值: $\hat{\mu} = \bar{x}$ 。将 $\hat{\mu}$ 代入关于 σ^2 的估计式中, 得到: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

情况 2: 当 $\bar{x} > \mu_0$, 此时, 无约束的最大值点 \bar{x} 在限制区域外面。因为 μ 有约束, 所以先讨论与 μ 相关的部分。进而确定无约束的参数。观察对数似然函数 $\ell(\mu, \sigma^2)$ 中关于 μ 的部分: $-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2$ 。这是一个开口向下的二次函数, 其对称轴为 $\mu = \bar{x}$ 。当 $\mu < \bar{x}$ 时, 该函数是单调递增的。因为我们的约束范围是 $\mu \leq \mu_0 < \bar{x}$, 所以在整个约束区间内, 函数值随着 μ 的增大而增大。因此, 最大值只能在边界 $\mu = \mu_0$ 处取得: $\hat{\mu} = \mu_0$ 。此时, 再将 $\hat{\mu} = \mu_0$ 代入对 σ^2 求偏导的方程, 得到: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2$

第五步: 综合结论综上所述, μ 和 σ^2 的极大似然估计为:

$$\hat{\mu} = \min(\bar{x}, \mu_0)$$

$$\hat{\sigma}^2 = \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, & \bar{x} \leq \mu_0 \\ \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2, & \bar{x} > \mu_0 \end{cases}$$

问题 16 (双样本问题, 仅做了解). 设 x_1, x_2, \dots, x_{n_1} 是来自正态总体 $N(\mu_1, \sigma^2)$ 的简单样本, y_1, y_2, \dots, y_{n_2} 是来自正态总体 $N(\mu_2 - \mu, \sigma^2)$ 的简单样本, 且两样本相互独立, 其中 $\mu \leq 0$ 。求参数 μ, μ_1, σ^2 的极大似然估计。

【解析】

解题思路: 这是一个双样本问题。令 $\mu_2 = \mu_1 - \mu$, 注意 $\mu \leq 0$ 意味着 $\mu_1 - \mu \geq \mu_1$, 则约束条件为 $\mu_2 \geq \mu_1$ 。

1 写出联合似然函数: 由于两个样本 X 和 Y 是相互独立的, 且样本内部也是独立同分布的, 所以联合似然函数等于所有观测值概率密度的乘积:

$$L(\mu_1, \mu_2, \sigma^2) = \left[\prod_{i=1}^{n_1} f(x_i; \mu_1, \sigma^2) \right] \cdot \left[\prod_{j=1}^{n_2} f(y_j; \mu_2, \sigma^2) \right]$$

代入正态分布公式:

$$L = \left[\prod_{i=1}^{n_1} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu_1)^2}{2\sigma^2}} \right] \cdot \left[\prod_{j=1}^{n_2} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_j - \mu_2)^2}{2\sigma^2}} \right]$$

合并指数项和常数项:

$$L = (2\pi\sigma^2)^{-\frac{n_1+n_2}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum_{i=1}^{n_1} (x_i - \mu_1)^2 + \sum_{j=1}^{n_2} (y_j - \mu_2)^2 \right] \right\}$$

取对数似然函数:

$$\ln L = -\frac{n_1+n_2}{2} \ln(2\pi) - \frac{n_1+n_2}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \left[\sum_{i=1}^{n_1} (x_i - \mu_1)^2 + \sum_{j=1}^{n_2} (y_j - \mu_2)^2 \right]$$

2 均值的估计:

无约束时, 对 μ_1, μ_2 求偏导, 最大值点显然在 $\hat{\mu}_1 = \bar{x}$ 和 $\hat{\mu}_2 = \bar{y}$ 。

若 $\bar{y} \geq \bar{x}$: 满足约束 $\mu_2 \geq \mu_1$ 。则 $\hat{\mu}_1 = \bar{x}, \hat{\mu}_2 = \bar{y}$ 。从而 $\hat{\mu} = \hat{\mu}_1 - \hat{\mu}_2 = \bar{x} - \bar{y}$ 。

若 $\bar{y} < \bar{x}$: 不满足约束。函数值在边界 $\mu_1 = \mu_2$ 处达到最大, 当我们在边界 $\mu_1 = \mu_2$ 寻找最值时, 我们可以令 $\mu_1 = \mu_2 = \mu^*$ (即假设两个样本来自同一个均值的总体)。此时, 对数似然函数中与均值相关的部分变为:

$$Q(\mu^*) = -\frac{1}{2\sigma^2} \left[\sum_{i=1}^{n_1} (x_i - \mu^*)^2 + \sum_{j=1}^{n_2} (y_j - \mu^*)^2 \right]$$

对 μ^* 求导并令其为 0:

$$\frac{dQ}{d\mu^*} = \frac{1}{\sigma^2} \left[\sum_{i=1}^{n_1} (x_i - \mu^*) + \sum_{j=1}^{n_2} (y_j - \mu^*) \right] = 0$$

展开求和:

$$\left(\sum x_i - n_1 \mu^* \right) + \left(\sum y_j - n_2 \mu^* \right) = 0$$

$$(n_1 + n_2) \mu^* = \sum x_i + \sum y_j$$

由于 $\sum x_i = n_1 \bar{x}$ 且 $\sum y_j = n_2 \bar{y}$, 解得:

$$\hat{\mu}^* = \frac{n_1 \bar{x} + n_2 \bar{y}}{n_1 + n_2}$$

这就是所谓的“合并均值”, 即把所有数据看作一伙的, 求总平均。从而 $\hat{\mu} = 0$ 。

3 方差的估计: 无论 μ_1, μ_2 取什么值, 我们对 σ^2 求偏导的逻辑是一样的。令 $S = \sum (x_i - \mu_1)^2 + \sum (y_j - \mu_2)^2$, 对数似然函数简化为:

$$\ell = C - \frac{n_1 + n_2}{2} \ln(\sigma^2) - \frac{S}{2\sigma^2}$$

对 σ^2 求偏导:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n_1 + n_2}{2\sigma^2} + \frac{S}{2(\sigma^2)^2} = 0$$

两边同乘 $2(\sigma^2)^2$:

$$-(n_1 + n_2)\sigma^2 + S = 0 \implies \hat{\sigma}^2 = \frac{S}{n_1 + n_2}$$

$$\hat{\sigma}^2 = \frac{1}{n_1 + n_2} [\sum (x_i - \hat{\mu}_1)^2 + \sum (y_j - \hat{\mu}_2)^2]。$$

总结: 若 $\bar{x} \leq \bar{y}$, $\hat{\mu}_1 = \bar{x}, \hat{\mu} = \bar{x} - \bar{y}$; 若 $\bar{x} > \bar{y}$, $\hat{\mu}_1 = \frac{n_1 \bar{x} + n_2 \bar{y}}{n_1 + n_2}, \hat{\mu} = 0$ 。

问题 17 (点估计应用题). 某家具厂需设计家用门高度, 要求人的头顶碰到上门框的机会不超过 0001。假设人的身高服从正态分布 $N(\mu, \sigma^2)$, x_1, x_2, \dots, x_n 是简单样本, 试给出门框最低高度的估计?

【解析】

第一步：建立数学模型

设人的身高为随机变量 X ，已知 $X \sim N(\mu, \sigma^2)$ 。设门框的高度为 h 。题目要求“头顶碰到上门框的机会不超过 0001”，即身高 X 大于高度 h 的概率要小于等于 0001： $P(X > h) \leq 0001$ 为了求出“最低”高度，我们取临界情况，即令 $P(X > h) = 0001$ 。

第二步：利用正态分布标准化寻找 h 的表达式

由于 $X \sim N(\mu, \sigma^2)$ ，我们将其标准化： $\frac{X - \mu}{\sigma} \sim N(0, 1)$ 于是概率式可以写为： $P\left(\frac{X - \mu}{\sigma} > \frac{h - \mu}{\sigma}\right) = 0001$ 根据标准正态分布的分位数定义，若 $Z \sim N(0, 1)$ ，使得 $P(Z > z_\alpha) = \alpha$ 的 z_α 称为上侧 α 分位数。这里 $\alpha = 0001$ ，所以有： $\frac{h - \mu}{\sigma} = z_{0001}$ 解得门框高度 h 的理论值为： $h = \mu + z_{0001}\sigma$ 查标准正态分布表可知 $z_{0001} \approx 301$

第三步：给出参数的估计量

在实际问题中，总体的均值 μ 和标准差 σ 是未知的。我们手头有样本 x_1, x_2, \dots, x_n ，需要用样本指标去估计它们。

均值 μ 的估计：样本均值 \bar{x} 是 μ 的无偏估计： $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

标准差 σ 的估计：样本标准差 s 是 σ 的无偏估计： $\hat{\sigma} = s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$

结论：根据参数估计的替换原理，将上述估计量代入 h 的表达式中，得到门框最低高度的估计量 \hat{h} 为： $\hat{h} = \bar{x} + 301s$ 。

1.3 均方误差和无偏估计

均方误差 (Mean Squared Error, MSE) 定义为估计值与真实值之差的平方的期望值，

$$MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

偏差 - 方差分解公式：

$$MSE(\hat{\theta}) = Var(\hat{\theta}) + [Bias(\hat{\theta})]^2 = Var(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2,$$

其中 $Bias(\hat{\theta}) = E(\hat{\theta}) - \theta$ 是偏差。

设 $\theta \in \mathbb{R}$ 是总体的未知参数 (例如: 总体均值 μ 、方差 σ^2 、比例 p 等), $\hat{\theta} = g(X_1, X_2, \dots, X_n)$ 是基于样本 X_1, \dots, X_n 构造的一个统计量。

若对所有可能的 θ 值, 都有:

$$\mathbb{E}_{\theta}[\hat{\theta}] = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计量, 下标 θ 表示期望是在参数真值为 θ 的分布下计算的。

经典例子: $\mathbb{E}[\bar{x} = \frac{1}{n} \sum x_i] = \mu$

$\mathbb{E}[S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2] = \sigma^2$ (用 n 代替 $n-1$ 则有偏)

无偏性不具有函数不变性: $\sqrt{S^2}$ 不是 σ 的无偏估计。

问题 18. 设总体 X 的数学期望 μ 和方差 σ^2 都存在, x_1, x_2, \dots, x_n 是来自总体 X 的简单样本, 统计量 \bar{x} 和 $a\bar{x}$ 是 μ 的两个估计, 其中 $a(0 < a < 1)$ 是已知常数。

1. 求均方误差 $E_{\theta}(\bar{x} - \mu)^2$ 和 $E_{\theta}(a\bar{x} - \mu)^2$, 其中 $\theta = (\mu, \sigma^2)$;
2. 问不等式 $E_{\theta}(a\bar{x} - \mu)^2 \leq E_{\theta}(\bar{x} - \mu)^2$ 是否对一切 $\theta \in \Theta = \{(\mu, \sigma^2) : -\infty < \mu < +\infty, \sigma^2 > 0\}$ 都成立? 若不成立, 给出使不等式成立的参数 θ 的范围。

【解析】

(1) 对于 \bar{x} : 我们知道 $E(\bar{x}) = \mu$, $Var(\bar{x}) = \frac{\sigma^2}{n}$ 。推导如下:

$$Var(\bar{x}) = Var\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} Var\left(\sum_{i=1}^n x_i\right) = \frac{1}{n^2} \underbrace{(\sigma^2 + \sigma^2 + \dots + \sigma^2)}_{n \uparrow} = \frac{1}{n^2} \cdot (n\sigma^2) = \frac{\sigma^2}{n}$$

所以, $E_{\theta}(\bar{x} - \mu)^2 = Var(\bar{x}) + [E(\bar{x}) - \mu]^2 = \frac{\sigma^2}{n}$ 。

对于 $a\bar{x}$: $E(a\bar{x}) = aE(\bar{x}) = a\mu$, $Bias(a\bar{x}) = E(a\bar{x}) - \mu = a\mu - \mu = (a-1)\mu$ 。

$$Var(a\bar{x}) = a^2 Var(\bar{x}) = \frac{a^2 \sigma^2}{n}。$$

所以, $E_{\theta}(a\bar{x} - \mu)^2 = Var(a\bar{x}) + [Bias(a\bar{x})]^2 = \frac{a^2 \sigma^2}{n} + (a-1)^2 \mu^2$ 。

(2) 考察不等式: $\frac{a^2 \sigma^2}{n} + (a-1)^2 \mu^2 \leq \frac{\sigma^2}{n}$, 移项得: $(a-1)^2 \mu^2 \leq \frac{\sigma^2}{n} - \frac{a^2 \sigma^2}{n} = \frac{(1-a^2)\sigma^2}{n}$

由于 $0 < a < 1$, 则 $1-a > 0$, 且 $1-a^2 = (1-a)(1+a)$ 。不等式两边同时除以 $(1-a)^2$:

$$\mu^2 \leq \frac{(1-a)(1+a)\sigma^2}{n(1-a)^2} = \frac{(1+a)\sigma^2}{n(1-a)}$$

由此可见, 不等式并非对一切 μ 都成立。**成立范围:** $|\mu| \leq \sqrt{\frac{1+a}{n(1-a)}} \sigma$ 。

问题 19. 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu_0, \sigma^2)$ 的简单样本, 其中 μ_0 是已知常数, σ^2 是未知参数。试在均方误差标准下, 比较未知参数 σ^2 的三个估计量

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad \hat{\sigma}_2^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_0)^2, \quad \hat{\sigma}_3^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

哪个较优?

【解析】

知识点拨: 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{\sum (x_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$, $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 。
卡方分布 $\chi^2(k)$ 的期望为 k , 方差为 $2k$ 。

1 对于 S^2 : 它是 σ^2 的无偏估计, 偏差为 0。

$$\text{Var}(S^2) = \frac{\sigma^4}{(n-1)^2} \text{Var}(\chi^2(n-1)) = \frac{\sigma^4}{(n-1)^2} \cdot 2(n-1) = \frac{2\sigma^4}{n-1}.$$

$$\text{故 } \text{MSE}(S^2) = \frac{2\sigma^4}{n-1}.$$

2 对于 $\hat{\sigma}_2^2$: 由于 μ_0 已知, $\frac{n\hat{\sigma}_2^2}{\sigma^2} \sim \chi^2(n)$ 。

$E(\hat{\sigma}_2^2) = \sigma^2$, 偏差为 0

$$\text{Var}(\hat{\sigma}_2^2) = \frac{\sigma^4}{n^2} \cdot 2n = \frac{2\sigma^4}{n}.$$

$$\text{故 } \text{MSE}(\hat{\sigma}_2^2) = \frac{2\sigma^4}{n}.$$

3 对于 $\hat{\sigma}_3^2$: 注意 $\hat{\sigma}_3^2 = \frac{n-1}{n} S^2$ 。

$$E(\hat{\sigma}_3^2) = \frac{n-1}{n} \sigma^2,$$

$$\text{Bias}(\hat{\sigma}_3^2)^2 = \left(\frac{n-1}{n} \sigma^2 - \sigma^2\right)^2 = \frac{\sigma^4}{n^2}.$$

$$\text{Var}(\hat{\sigma}_3^2) = \left(\frac{n-1}{n}\right)^2 \text{Var}(S^2) = \frac{(n-1)^2}{n^2} \frac{2\sigma^4}{n-1} = \frac{2(n-1)\sigma^4}{n^2}.$$

$$\text{MSE}(\hat{\sigma}_3^2) = \frac{2n-2}{n^2} \sigma^4 + \frac{1}{n^2} \sigma^4 = \frac{2n-1}{n^2} \sigma^4.$$

$$\text{比较: } \text{MSE}(S^2) = \frac{2}{n-1} \sigma^4 > \text{MSE}(\hat{\sigma}_2^2) = \frac{2}{n} \sigma^4.$$

$$\text{MSE}(\hat{\sigma}_2^2) - \text{MSE}(\hat{\sigma}_3^2) = \left(\frac{2}{n} - \frac{2n-1}{n^2}\right) \sigma^4 = \frac{2n - (2n-1)}{n^2} \sigma^4 = \frac{1}{n^2} \sigma^4 > 0.$$

因此, $\text{MSE}(\hat{\sigma}_3^2) < \text{MSE}(\hat{\sigma}_2^2) < \text{MSE}(S^2)$, $\hat{\sigma}_3^2$ 最优, 这说明有时放弃无偏性可以换取更小的均方误差。

问题 20. 设总体 X 服从两点分布 $B(1, p)$, 其中 $p(0 < p < 1)$ 是未知参数。

1. x_1 是来自总体 X 的简单样本, 试问对 p 及 p^2 是否存在无偏估计?

2. x_1, x_2, \dots, x_n 是来自总体 X 的简单样本, 求参数 p^2 的无偏估计 ($n \geq 2$)。

【解析】

(1) 对于 p : 令 $\hat{p} = x_1$, 则 $E(x_1) = 1 \cdot p + 0 \cdot (1-p) = p$ 。所以 x_1 是 p 的无偏估计。

对于 p^2 : 设存在无偏估计 $g(x_1)$, 则 $E[g(x_1)] = g(1)p + g(0)(1-p) = p^2$ 。整理得: $(g(1) - g(0))p + g(0) = p^2$ 。这是一个关于 p 的恒等式, 但左边是 p 的一次多项式, 右边是二次。多项式恒等定理告诉我们: 如果两个多项式在某个区间内处处相等, 那么它们对应的各项系数必须完全相同。故不存在 p^2 的无偏估计。

(2) 当 $n \geq 2$ 时, 我们需要构造一个统计量使其期望为 p^2 。

考虑样本均值 \bar{x} , 我们知道 $E(\bar{x}) = p$, $Var(\bar{x}) = \frac{p(1-p)}{n}$ 。

则 $E(\bar{x}^2) = Var(\bar{x}) + [E(\bar{x})]^2 = \frac{p-p^2}{n} + p^2 = \frac{n-1}{n}p^2 + \frac{1}{n}p$ 。

这还不是 p^2 。但我们注意到 $E(\bar{x}) = p$, 可以利用它消去 $\frac{1}{n}p$ 项。

令 $E[\bar{x}^2 - \frac{1}{n}\bar{x}] = \frac{n-1}{n}p^2 + \frac{1}{n}p - \frac{1}{n}p = \frac{n-1}{n}p^2$ 。

所以, $\hat{p}^2 = \frac{n}{n-1}(\bar{x}^2 - \frac{1}{n}\bar{x}) = \frac{n\bar{x}^2 - \bar{x}}{n-1}$ 是 p^2 的无偏估计。

问题 21. 设 x_1, x_2, x_3 是来自总体 X 的简单样本 (相互独立), 试证明下列估计量

$$\hat{\mu}_1 = \frac{1}{5}x_1 + \frac{3}{10}x_2 + \frac{1}{2}x_3, \quad \hat{\mu}_2 = \frac{1}{3}x_1 + \frac{1}{4}x_2 + \frac{5}{12}x_3, \quad \hat{\mu}_3 = \frac{1}{3}x_1 + \frac{3}{4}x_2 - \frac{1}{12}x_3$$

都是总体均值 $E(X) = \mu$ 的无偏估计, 并求出每个估计的方差, 问哪个估计较优?

【解析】

证明无偏性: 对于线性组合 $\sum c_i x_i$, 其期望为 $\mu \sum c_i$ 。只需检查系数之和是否为 1。

$$1 \hat{\mu}_1: \frac{1}{5} + \frac{3}{10} + \frac{1}{2} = \frac{2+3+5}{10} = 1。$$

$$2 \hat{\mu}_2: \frac{1}{3} + \frac{1}{4} + \frac{5}{12} = \frac{4+3+5}{12} = 1。$$

$$3 \hat{\mu}_3: \frac{1}{3} + \frac{3}{4} - \frac{1}{12} = \frac{4+9-1}{12} = 1。$$

所以, 三者均为无偏估计。

计算方差: $Var(\sum c_i x_i) = \sigma^2 \sum c_i^2$ 。

$$1 Var(\hat{\mu}_1) = \sigma^2[(\frac{2}{10})^2 + (\frac{3}{10})^2 + (\frac{5}{10})^2] = \frac{4+9+25}{100}\sigma^2 = 038\sigma^2。$$

$$2 Var(\hat{\mu}_2) = \sigma^2[(\frac{4}{12})^2 + (\frac{3}{12})^2 + (\frac{5}{12})^2] = \frac{16+9+25}{144}\sigma^2 = \frac{50}{144}\sigma^2 \approx 0347\sigma^2。$$

$$3 Var(\hat{\mu}_3) = \sigma^2[(\frac{4}{12})^2 + (\frac{9}{12})^2 + (-\frac{1}{12})^2] = \frac{16+81+1}{144}\sigma^2 = \frac{98}{144}\sigma^2 \approx 0681\sigma^2。$$

结论: 因为 $Var(\hat{\mu}_2)$ 最小, 所以在无偏估计类中 $\hat{\mu}_2$ 最优。

问题 22. 设总体 $X \sim U[0, \theta](\theta > 0)$, x_1, x_2, \dots, x_n 是来自总体 X 的简单样本, $x_{(n)}$ 是参数 θ 的极大似然估计, 令 $\hat{\theta}(c) = cx_{(n)}$, 其中 c 是常数。

1. 求均方误差 $MSE_{\theta}(\hat{\theta}(c))$;

2. 求常数 c , 使得均方误差 $MSE_{\theta}(\hat{\theta}(c))$ 最小;

3. 记 (2) 中使 MSE 最小的估计为 $\hat{\theta}_1$, 证明 $\hat{\theta}_1$ 是 θ 的有偏估计。这说明在均方误差标准下, θ 的有偏估计 $\hat{\theta}_1$ 要比其无偏估计 $\hat{\theta}_2 = \frac{n+1}{n}x_{(n)}$ 优。

均匀分布 $U[0, \theta]$ 的最小次序统计量 $x_{(1)}$ 和最大次序统计量 $x_{(n)}$ 的期望分别为 $E(x_{(1)}) = \frac{\theta}{n+1}$, $E(x_{(n)}) = \frac{n}{n+1}\theta$ 。对于 $U[0, \theta]$ 分布的最大值 $x_{(n)}$, 它的 k 阶原点矩 (即 $x_{(n)}^k$ 的期望) 公式为: $E(x_{(n)}^k) = \frac{n}{n+k}\theta^k$

直观理解: n 个点把 $[0, \theta]$ 分成 $n+1$ 段, 平均每段长度就是 $\frac{\theta}{n+1}$ 。最小值的期望就是第一段的长度, 最大值的期望是前 n 段的总长。

【解析】

(1) 已知 $E(x_{(n)}) = \frac{n}{n+1}\theta$, $E(x_{(n)}^2) = \frac{n}{n+2}\theta^2$ 。

$$\text{则 } \text{Var}(x_{(n)}) = \frac{n}{n+2}\theta^2 - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n\theta^2}{(n+2)(n+1)^2}。$$

$$\text{MSE}(cx_{(n)}) = \text{Var}(cx_{(n)}) + [E(cx_{(n)}) - \theta]^2 = c^2 \frac{n\theta^2}{(n+2)(n+1)^2} + \left(\frac{cn}{n+1} - 1\right)^2 \theta^2。$$

(2) 对 c 求导并令其为 0:

$$\frac{d}{dc} \text{MSE} = \theta^2 \left[\frac{2cn}{(n+2)(n+1)^2} + 2\left(\frac{cn}{n+1} - 1\right) \frac{n}{n+1} \right] = 0$$

$$\text{化简得: } \frac{c}{(n+2)(n+1)} + \frac{cn}{n+1} - 1 = 0 \implies c \left[\frac{1+n(n+2)}{(n+2)(n+1)} \right] = 1$$

$$c \frac{(n+1)^2}{(n+2)(n+1)} = 1 \implies c \frac{n+1}{n+2} = 1 \implies c = \frac{n+2}{n+1}。$$

(3) $\hat{\theta}_1 = \frac{n+2}{n+1}x_{(n)}$ 。其期望 $E(\hat{\theta}_1) = \frac{n+2}{n+1} \cdot \frac{n}{n+1}\theta = \frac{n(n+2)}{(n+1)^2}\theta \neq \theta$, 故是有偏的。

由于 $c = \frac{n+2}{n+1}$ 是使 MSE 最小的唯一解, 而无偏估计 $\hat{\theta}_2$ 对应的 $c = \frac{n+1}{n}$, 故 $\hat{\theta}_1$ 的 MSE 必然小于 $\hat{\theta}_2$ 的 MSE。

1.4 一致最小方差无偏估计 UMVUE

Rao-Blackwell 定理

定理内容: 设 T 是参数 θ 的充分统计量, $\hat{\theta}$ 是 θ 的一个无偏估计量。定义一个新的估计量:

$$\eta(T) = E[\hat{\theta}|T]$$

则有:

1. $\eta(T)$ 也是 θ 的无偏估计量, 即 $E[\eta(T)] = \theta$;
2. $\eta(T)$ 的方差小于或等于 $\hat{\theta}$ 的方差, 即 $\text{Var}(\eta(T)) \leq \text{Var}(\hat{\theta})$ 。

Lehmann-Scheffé 定理

定理内容：若统计量 $T(X)$ 是参数 θ 的完备充分统计量，且 $\varphi(X)$ 是 $q(\theta)$ 的一个无偏估计，则条件期望 $g(T) = E[\varphi(X) | T(X)]$ 是 $q(\theta)$ 的唯一的一致最小方差无偏估计 (UMVUE)。

应用说明：寻找 UMVUE 的标准方案：

1 找 $q(\theta)$ 的完备充分统计量 $T(X)$ ，大多是情况就是找充分统计量，基本上不会出现非完备情况。

2 找到一个 $T(X)$ 的函数 $\varphi(X)$ 是无偏估计，也就是 $E[\varphi(X)] = q(\theta)$

3 $\varphi(X)$ 就是 $q(\theta)$ 的一致最小方差无偏估计 (UMVUE)。

注：指数族在自然参数空间内通常是完备的（如正态、泊松、伽马、二项、伯努利、均匀 $U(0, \theta)$ 的倒数形式等）。不需要每次都验证完备性，记住：“常见单参数指数族 \rightarrow 充分统计量自动完备”。

问题 23. 设 x_1, x_2, \dots, x_n 是来自 *Poisson* 总体 $P(\lambda)$ 的简单样本， λ 是正的未知参数。对于已知的正整数 k ，试求 $q(\lambda) = \frac{\lambda^k}{k!} e^{-\lambda}$ 的一致最小方差无偏估计 (UMVUE)。

【解析】**第一步：寻找参数 λ 的完备充分统计量**

Poisson 分布概率质量函数为：

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

样本 x_1, x_2, \dots, x_n 的联合分布为：

$$L(\lambda; x_1, \dots, x_n) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!}$$

根据因子分解定理，联合分布可分解为：

$$L(\lambda; \mathbf{x}) = \underbrace{(\lambda^{\sum x_i} e^{-n\lambda})}_{g(T(\mathbf{x}), \lambda)} \cdot \underbrace{\left(\frac{1}{\prod x_i!} \right)}_{h(\mathbf{x})}$$

其中 $T(x) = \sum_{i=1}^n x_i$ 。因此， $T = \sum_{i=1}^n x_i$ 是参数 λ 的充分统计量。又因为 *Poisson* 分布属于指数族，且参数空间包含内点，故 $T = \sum_{i=1}^n x_i$ 是 λ 的完备充分统计量。

第二步：构造待估参数 $q(\lambda)$ 的无偏估计量

待估参数为 $q(\lambda) = \frac{\lambda^k}{k!} e^{-\lambda}$ ，这恰好是总体中单个随机变量取值为 k 的概率，即 $q(\lambda) = P(X_1 = k)$ 。定义观测值 x_1 的函数 $u(x_1)$ 如下：

$$u(x_1) = I_{\{x_1=k\}} = \begin{cases} 1, & x_1 = k \\ 0, & x_1 \neq k \end{cases}$$

验证其无偏性: $E[u(x_1)] = 1 \cdot P(x_1 = k) + 0 \cdot P(x_1 \neq k) = \frac{\lambda^k e^{-\lambda}}{k!} = q(\lambda)$

故 $u(x_1)$ 是 $q(\lambda)$ 的一个无偏估计量。

第三步: 利用 Lehmann-Scheffé 定理求 UMVUE

根据 Lehmann-Scheffé 定理, 由于 T 是完备充分统计量, 且 $u(x_1)$ 是无偏估计量, 则 $q(\lambda)$ 的 UMVUE 为:

$$\hat{q}(\lambda) = E[u(x_1)|T = t] = 1 \cdot P(u(x_1) = 1|T = t) + 0 \cdot P(u(x_1) = 0|T = t) = P(x_1 = k | \sum_{i=1}^n x_i = t)$$

到这一步都应该能写出来

第四步: 详细计算条件概率

根据条件概率定义及样本的独立性:

$$P(x_1 = k | \sum_{i=1}^n x_i = t) = \frac{P(x_1 = k, \sum_{i=1}^n x_i = t)}{P(\sum_{i=1}^n x_i = t)} = \frac{P(x_1 = k, \sum_{i=2}^n x_i = t - k)}{P(\sum_{i=1}^n x_i = t)}$$

由于 x_i 独立同分布于 $P(\lambda)$, 根据 Poisson 分布的可加性: $\sum_{i=2}^n x_i \sim P((n-1)\lambda)$, 且 $\sum_{i=1}^n x_i \sim P(n\lambda)$ 。代入概率质量函数公式:

$$\hat{q} = \frac{\left(\frac{\lambda^k e^{-\lambda}}{k!}\right) \cdot \left(\frac{[(n-1)\lambda]^{t-k} e^{-(n-1)\lambda}}{(t-k)!}\right)}{\frac{(n\lambda)^t e^{-n\lambda}}{t!}}$$

消去分子分母中的 $e^{-n\lambda}$ 和 λ^t :

$$\hat{q} = \frac{t!}{k!(t-k)!} \cdot \frac{(n-1)^{t-k}}{n^t}$$

进一步整理:

$$\hat{q} = \binom{t}{k} \frac{(n-1)^{t-k}}{n^{t-k} \cdot n^k} = \binom{t}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{t-k}$$

结论: $q(\lambda)$ 的一致最小方差无偏估计为:

$$\hat{q}(\lambda) = \begin{cases} \binom{\sum_{i=1}^n x_i}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{\sum_{i=1}^n x_i - k}, & \sum x_i \geq k \\ 0, & \sum x_i < k \end{cases}$$

问题 24 (重要结论). 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本。(1) 当 σ^2 已知时, 求 μ 的 UMVUE; (2) 当 μ 已知时, 求 σ^2 的 UMVUE。

【解析】

(1) 当 σ^2 已知时, 求 μ 的 UMVUE

第一步: 写出样本的联合概率密度函数

总体密度为 $f(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$ 。

样本的联合密度函数为: $L(\mathbf{x}; \mu) = \prod_{i=1}^n f(x_i; \mu) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$
 展开指数部分: $\sum (x_i - \mu)^2 = \sum x_i^2 - 2\mu \sum x_i + n\mu^2$ 。代入整理得:

$$L(\mathbf{x}; \mu) = \underbrace{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{\sum x_i^2}{2\sigma^2}\right\}}_{h(\mathbf{x})} \cdot \underbrace{\exp\left\{-\frac{n\mu^2}{2\sigma^2}\right\} \exp\left\{\frac{\mu}{\sigma^2} \sum_{i=1}^n x_i\right\}}_{g(T(\mathbf{x}), \mu)}$$

第二步: 寻找完备充分统计量

根据因子分解定理, 统计量 $T = \sum_{i=1}^n x_i$ 是参数 μ 的充分统计量。

由于正态分布属于指数族分布, 且参数空间 $\Theta = (-\infty, +\infty)$ 包含内点, 因此, $T = \sum_{i=1}^n x_i$ 是 μ 的完备充分统计量。

第三步: 构造无偏估计

我们需要寻找一个基于 T 的函数 $\phi(T)$, 使其满足 $E[\phi(T)] = \mu$ 。考察统计量 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{T}{n}$ 。由于 $x_i \sim N(\mu, \sigma^2)$, 根据期望的线性性质: $E[\bar{x}] = E\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n} \sum_{i=1}^n E[x_i] = \frac{1}{n} \cdot n\mu = \mu$, 即 \bar{x} 是 μ 的无偏估计。

第四步: 利用 Lehmann-Scheffé 定理得出结论

因为 \bar{x} 是完备充分统计量 T 的函数, 且是 μ 的无偏估计。根据 Lehmann-Scheffé 定理, $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 是 μ 的一致最小方差无偏估计 (UMVUE)。

(2) 当 μ 已知时, 求 σ^2 的 UMVUE

第一步: 写出样本的联合概率密度函数

$$L(\mathbf{x}; \sigma^2) = (2\pi)^{-\frac{n}{2}} (\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

第二步: 寻找完备充分统计量

根据因子分解定理, 可以看出统计量 $S = \sum_{i=1}^n (x_i - \mu)^2$ 是 σ^2 的充分统计量。同样地, 将密度函数写成指数族形式: $L(\mathbf{x}; \sigma^2) = (2\pi)^{-\frac{n}{2}} \exp\left\{-\frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} S\right\}$ 这构成了关于参数 $\theta = -\frac{1}{2\sigma^2}$ 的指数族分布。由于参数空间包含内点, 故统计量 $S = \sum_{i=1}^n (x_i - \mu)^2$ 是 σ^2 的完备充分统计量。

第三步: 构造无偏估计

我们需要寻找一个基于 S 的函数, 使其期望等于 σ^2 。首先我们需要计算 S 的期望, 根据结果考虑如何修正。

已知 $\frac{x_i - \mu}{\sigma} \sim N(0, 1)$, 则 $\left(\frac{x_i - \mu}{\sigma}\right)^2 \sim \chi^2(1)$ 。根据卡方分布的可加性: $\frac{S}{\sigma^2} = \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$

利用卡方分布的期望性质 $E[\chi^2(n)] = n$, 有:

$$E\left[\frac{S}{\sigma^2}\right] = n \implies \frac{1}{\sigma^2} E[S] = n \implies E[S] = n\sigma^2$$

为了得到 σ^2 , 我们将等式两边除以 n : $E\left[\frac{S}{n}\right] = \sigma^2$

因此, $\hat{\sigma}^2 = \frac{S}{n} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ 是 σ^2 的无偏估计。

第四步: 利用 Lehmann-Scheffé 定理得出结论

因为 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ 是完备充分统计量 S 的函数, 且是 σ^2 的无偏估计。根据 Lehmann-Scheffé 定理, 它是 σ^2 的 UMVUE。

问题 25. 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, 其中 μ, σ^2 是未知参数。若用 $\hat{\mu}^2 = \bar{x}^2 - \frac{1}{n} S^2$ 作为 μ^2 的估计, 证明 $\hat{\mu}^2$ 是 μ^2 的 UMVUE。

【解析】

1 **完备充分性:** 在正态总体参数均未知时, (\bar{x}, S^2) 是 (μ, σ^2) 的完备充分统计量。 $\hat{\mu}^2$ 是这两个统计量的函数。

由正态分布的指数族形式, 联合密度可分解为:

$$f(x_1, \dots, x_n | \mu, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \exp \left(-\frac{\sum x_i^2}{2\sigma^2} + \frac{\mu}{\sigma^2} \sum x_i - \frac{n\mu^2}{2\sigma^2} \right)$$

μ, σ^2 是未知参数, 根据因子分解定理, 充分统计量为:

$$\left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$$

等价于常用形式:

$$(\bar{X}, S^2) = \left(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right)$$

注: 在正态总体下, (\bar{x}, S^2) 的充分完全性通常作为已知结论直接引用即可, 不需要重新证明。

2 **无偏性:** 我们需要证明 $E[\hat{\mu}^2] = \mu^2$ 。已知 $E[\bar{x}] = \mu$, $Var(\bar{x}) = \frac{\sigma^2}{n}$ 。利用公式 $E[\bar{x}^2] = Var(\bar{x}) + (E[\bar{x}])^2 = \frac{\sigma^2}{n} + \mu^2$ 。又已知 $E[S^2] = \sigma^2$ 。则:

$$E[\hat{\mu}^2] = E\left[\bar{x}^2 - \frac{1}{n} S^2\right] = E[\bar{x}^2] - \frac{1}{n} E[S^2] = \left(\mu^2 + \frac{\sigma^2}{n}\right) - \frac{\sigma^2}{n} = \mu^2$$

3 **结论:** 由于 $\hat{\mu}^2$ 是完备充分统计量的函数, 且是 μ^2 的无偏估计, 根据 Lehmann-Scheffé 定理, $\hat{\mu}^2$ 是 μ^2 的 UMVUE。

问题 26. 设总体 $X \sim B(1, p)$, x_1, \dots, x_n 是简单样本, 求 p 的 UMVUE。

【解析】

一、核心定理回顾 Lehmann-Scheffé 定理: 若 T 是 θ 的充分完备统计量, 且 $g(T)$ 是 θ 的无偏估计, 则 $g(T)$ 是 θ 的 UMVUE。

1. 寻找充分统计量

$X \sim B(1, p)$, 联合分布列:

$$L(x_1, \dots, x_n; p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

令 $T = \sum_{i=1}^n x_i$, 则:

$$f = p^T (1-p)^{n-T} \cdot 1$$

故 T 是 p 的充分统计量。

3. 完备性验证

由于伯努利分布属于**指数族分布**, 且**参数空间包含内点**, 所以充分统计量 $T = \sum_{i=1}^n x_i$ 也是完备的。因此, $T = \sum_{i=1}^n x_i$ 是 p 的完备充分统计量。

4. 无偏估计构造

$$E[T] = np \rightarrow E\left[\frac{T}{n}\right] = p, \text{ 即 } \frac{T}{n} \text{ 是无偏估计。}$$

5. 由 Lehmann-Scheffé 定理, $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$ 是 p 的 UMVUE。

问题 27 (了解). 设 $x_1, \dots, x_m \sim N(\mu_1, \sigma^2)$, $y_1, \dots, y_n \sim N(\mu_2, \sigma^2)$, 两样本独立, 参数均未知。求 μ_1, μ_2, σ^2 的 UMVUE。

【解析】**第一步: 写出联合概率密度函数并整理**

由于样本独立, 联合概率密度函数 (似然函数) 为两组样本密度的乘积:

$$\begin{aligned} L(\mu_1, \mu_2, \sigma^2) &= \left(\prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x_i - \mu_1)^2}{2\sigma^2}} \right) \cdot \left(\prod_{j=1}^n \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(y_j - \mu_2)^2}{2\sigma^2}} \right) \\ &= (2\pi\sigma^2)^{-\frac{m+n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum_{i=1}^m (x_i - \mu_1)^2 + \sum_{j=1}^n (y_j - \mu_2)^2 \right] \right\} \end{aligned}$$

展开指数部分的平方项:

$$\sum_{i=1}^m (x_i - \mu_1)^2 = \sum_{i=1}^m x_i^2 - 2\mu_1 \sum_{i=1}^m x_i + m\mu_1^2$$

$$\sum_{j=1}^n (y_j - \mu_2)^2 = \sum_{j=1}^n y_j^2 - 2\mu_2 \sum_{j=1}^n y_j + n\mu_2^2$$

代回似然函数并整理成指数族形式:

$$L = C(\mu_1, \mu_2, \sigma^2) \exp \left\{ \frac{\mu_1}{\sigma^2} \sum_{i=1}^m x_i + \frac{\mu_2}{\sigma^2} \sum_{j=1}^n y_j - \frac{1}{2\sigma^2} \left(\sum_{i=1}^m x_i^2 + \sum_{j=1}^n y_j^2 \right) \right\}$$

其中 $C(\cdot)$ 是仅包含参数的项。

第二步: 确定完备充分统计量

根据因子分解定理, 联合充分统计量为: $T = \left(\sum_{i=1}^m x_i, \sum_{j=1}^n y_j, \sum_{i=1}^m x_i^2 + \sum_{j=1}^n y_j^2 \right)$

由于正态分布属于指数族分布, 且参数空间 $\Theta = \{(\mu_1, \mu_2, \sigma^2) : \mu_1 \in \mathbb{R}, \mu_2 \in \mathbb{R}, \sigma^2 > 0\}$ 包含内点, 因此统计量 T 是完备充分统计量。

由于完备充分统计量是一一变换不变量, 我们可以将 T 转换为更常用的形式。令:

$$\bar{x} = \frac{1}{m} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_j, \quad S_{pooled}^2 = \sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{j=1}^n (y_j - \bar{y})^2$$
 利用恒等式 $\sum x_i^2 = \sum (x_i - \bar{x})^2 + m\bar{x}^2$, 可知 $(\bar{x}, \bar{y}, S_{pooled}^2)$ 与原统计量 T 是一一对应的。因此, $T^* = (\bar{x}, \bar{y}, S_{pooled}^2)$ 也是完备充分统计量。

第三步: 构造无偏估计并应用 Lehmann-Scheffé 定理

根据 Lehmann-Scheffé 定理, 若 \hat{g} 是参数 $g(\theta)$ 的无偏估计, 且 \hat{g} 是完备充分统计量的函数, 则 \hat{g} 是 $g(\theta)$ 的 UMVUE。

对于 μ_1 : 我们知道 $E[\bar{x}] = \mu_1$ 。且 \bar{x} 是完备充分统计量 T^* 的函数。

$\therefore \hat{\mu}_1 = \bar{x}$ 是 μ_1 的 UMVUE。

对于 μ_2 : 同理, $E[\bar{y}] = \mu_2$ 。且 \bar{y} 是完备充分统计量 T^* 的函数。

$\therefore \hat{\mu}_2 = \bar{y}$ 是 μ_2 的 UMVUE。

对于 σ^2 : 我们需要利用样本方差的性质。对于第一个样本: $\frac{1}{\sigma^2} \sum_{i=1}^m (x_i - \bar{x})^2 \sim \chi^2(m-1)$ 。对于第二个样本: $\frac{1}{\sigma^2} \sum_{j=1}^n (y_j - \bar{y})^2 \sim \chi^2(n-1)$ 。由于两样本独立, 卡方分布具有可加性: $\frac{1}{\sigma^2} \left[\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{j=1}^n (y_j - \bar{y})^2 \right] \sim \chi^2(m-1+n-1) = \chi^2(m+n-2)$ 已知卡方分布 $\chi^2(k)$ 的期望为 k , 故:

$$E \left[\frac{S_{pooled}^2}{\sigma^2} \right] = m+n-2, \quad E \left[\frac{S_{pooled}^2}{m+n-2} \right] = \sigma^2$$

构造统计量 $\hat{\sigma}^2 = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{j=1}^n (y_j - \bar{y})^2}{m+n-2}$ 。它是 σ^2 的无偏估计, 且仅依赖于完备充分统计量 S_{pooled}^2 。

$\therefore \hat{\sigma}^2 = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{j=1}^n (y_j - \bar{y})^2}{m+n-2}$ 是 σ^2 的 UMVUE。

综上所述:

- μ_1 的 UMVUE 为 $\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$
- μ_2 的 UMVUE 为 $\bar{y} = \frac{1}{n} \sum_{j=1}^n y_j$
- σ^2 的 UMVUE 为 $S^2 = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{j=1}^n (y_j - \bar{y})^2}{m+n-2}$

1.5 假设检验

1.5.1 基本概念

在假设检验问题 $H_0: \theta \in \Theta_0, H_1: \theta \in \Theta_1$ 中, 我们需要根据样本 X 决定接受 H_0 还是拒绝 H_0 。

定义 1.5.1 (检验函数与拒绝域). 检验通常由拒绝域 W 或检验函数 $\phi(x)$ 表示:

$$\phi(x) = \begin{cases} 1, & x \in W \quad (\text{拒绝 } H_0) \\ 0, & x \notin W \quad (\text{接受 } H_0) \end{cases}$$

定义 1.5.2 (势函数与两类错误). 势函数 $g(\theta)$ 定义为拒绝原假设的概率:

$$g(\theta) = E_\theta[\phi(X)] = P_\theta(X \in W)$$

- **第一类错误概率 (拒真):** 当 H_0 实际成立时, 却错误地拒绝了 H_0

$$\alpha(\theta) = g(\theta), \quad \theta \in \Theta_0$$

- **显著性水平 α 为 H_0 为真时拒绝 H_0 的概率:** 通常要求第一类错误概率最大不超过预设的显著性水平 α , $\sup_{\theta \in \Theta_0} g(\theta) \leq \alpha$ 。

- **第二类错误概率 (取伪):** 当 H_1 实际成立时, 却错误地接受了 H_0 。

$$\beta(\theta) = 1 - g(\theta), \quad \theta \in \Theta_1$$

- **检验的势指当备择假设 H_1 为真时, 正确拒绝原假设 H_0 的概率。:**

$$Power = g(\theta), \quad \theta \in \Theta_1$$

1.5.2 常见统计量

设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。

1. σ^2 已知, 检验 μ : 统计量 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ 。
2. σ^2 未知, 检验 μ : 统计量 $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。
3. μ 已知, 检验 σ^2 : 统计量 $\chi^2 = \frac{\sum (X_i - \mu)^2}{\sigma_0^2} \sim \chi^2(n)$ 。
4. μ 未知, 检验 σ^2 : 统计量 $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$ 。

1.6 似然比检验

1.6.1 定义与步骤

似然比检验是一种通用的构造检验的方法。 \sup 指 ‘上确界’，是所有上界中最小的那个。

定义 1.6.1 (似然比统计量).

$$\lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta; x)}{\sup_{\theta \in \Theta} L(\theta; x)}$$

拒绝域形式为 $W = \{x : \lambda(x) \leq c\}$ ，其中 c 由显著性水平 α 确定：

$$\sup_{\theta \in \Theta_0} P_{\theta}(\lambda(X) \leq c) = \alpha$$

解题步骤：

1. 写出似然函数 $L(\theta)$ 。
2. 在全参数空间 Θ 上求极大似然估计 $\hat{\theta}$ 及最大值 $L(\hat{\theta})$ 。
3. 在原假设空间 Θ_0 上求受限极大似然估计 $\hat{\theta}_0$ 及最大值 $L(\hat{\theta}_0)$ 。
4. 计算 $\lambda(x)$ 并化简不等式 $\lambda(x) \leq c$ 。通常能化简为关于充分统计量的单调函数，从而确定等价的拒绝域形式。

1.6.2 一致最大势检验 (UMPT)

引理 1 (Neyman-Pearson 引理). 处理简单假设 $H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$ 。拒绝域由似然比 $\frac{L(\theta_1)}{L(\theta_0)} > k$ 确定。

定义 1.6.2 (单调似然比分布族). 设单参数分布族 $\{f(x|\theta), \theta \in \Theta\}$ ，若存在统计量 $T(X)$ ，使得对任意 $\theta_1 < \theta_2$ ，似然比 $\frac{f(x|\theta_2)}{f(x|\theta_1)}$ 是 $T(X)$ 的非递减函数（或非递增函数），则称该分布族对 $T(X)$ 具有单调似然比 (monotone likelihood ratio, MLR)。

定理 1 (Karlin-Rubin 定理). 条件：单参数分布族 $\{f(x|\theta)\}$ 对统计量 $T(X)$ 具有单调似然比；

检验单侧假设： $H_0 : \theta \leq \theta_0$ vs $H_1 : \theta > \theta_0$ (右侧检验)，或 $H_0 : \theta \geq \theta_0$ vs $H_1 : \theta < \theta_0$ (左侧检验)。

结论：存在基于 $T(X)$ 的一致最优势检验 (UMPT)，其拒绝域为：

右侧检验： $T(X) > c$ ；左侧检验： $T(X) < c$ 。

其中， c 由显著性水平 α 确定， c 满足 $P_{\theta_0}(T(X) > c) = \alpha$ (右侧) 或 $P_{\theta_0}(T(X) < c) = \alpha$ (左侧)。

1.6.3 一致最大势无偏检验 (UMPUT)

用于处理双边检验问题, 如 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$, 或者区间假设。

无偏性

检验 ϕ 是无偏的, 如果:

$$\sup_{\theta \in \Theta_0} g(\theta) \leq \alpha \leq \inf_{\theta \in \Theta_1} g(\theta)$$

即犯第一类错误的概率不超过 α , 且犯第二类错误的概率不超过 $1 - \alpha$ (势不低于 α)。

指数族的 UMPUT

对于单参数指数族分布, 考虑双边检验 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。UMPUT 的拒绝域形式通常为两边拒绝:

$$W = \{T(X) < C_1 \text{ 或 } T(X) > C_2\}$$

确定常数 C_1, C_2 需联立以下两个方程:

1. 显著性水平条件

在原假设下, 拒绝原假设的概率必须等于显著性水平 α :

$$P_{\theta_0}(T(X) < C_1) + P_{\theta_0}(T(X) > C_2) = \alpha$$

该条件保证了第一类错误率严格控制在 α 以内。

2. 无偏性条件

无偏性要求势函数 $g(\theta) = P_{\theta}(X \in W)$ 在 $\theta = \theta_0$ 处达到最小值 α , 因此势函数在 θ_0 处的导数为 0: $g'(\theta_0) = 0$ 。对势函数求导可得:

$$\left. \frac{d}{d\theta} [P_{\theta}(T < C_1) + P_{\theta}(T > C_2)] \right|_{\theta=\theta_0} = 0$$

结合指数族的得分函数性质, 该条件等价于:

$$E_{\theta_0} [T(X) \cdot I(T < C_1)] + E_{\theta_0} [T(X) \cdot I(T > C_2)] = \alpha \cdot E_{\theta_0} [T(X)]$$

即拒绝域中统计量的加权均值等于原假设下统计量均值的 α 倍。

1.6.4 练习题

问题 28. 设总体 X 服从两点分布 $B(1, p)$, x_1, x_2, x_3 是来自总体 X 的简单样本, 考虑假设检验问题 $H_0: p = \frac{1}{2}, H_1: p = \frac{3}{4}$ 。若取拒绝域

$$W = \{(x_1, x_2, x_3) : x_1 + x_2 + x_3 \geq 1\}$$

求势函数, 以及犯第一类错误和第二类错误的概率及势。

【解析】**1 确定检验统计量及其分布**

设 $T = \sum_{i=1}^3 X_i$ 为样本中取值为 1 的个数。由于 X_1, X_2, X_3 独立同分布于 $B(1, p)$ ，根据二项分布的可加性，统计量 T 服从二项分布：

$$T \sim B(3, p)$$

其概率分布律为：

$$P(T = k) = \binom{3}{k} p^k (1-p)^{3-k}, \quad k = 0, 1, 2, 3$$

2 确定拒绝域

题目给出的拒绝域为 $W = \{(x_1, x_2, x_3) : x_1 + x_2 + x_3 \geq 1\}$ 。用统计量 T 表示，拒绝域即为：

$$W = \{T \geq 1\}$$

这意味着，只要样本中至少有一个 1，我们就拒绝原假设 H_0 。

3 求势函数 $g(p)$

势函数 $g(p)$ 定义为在参数为 p 时，样本落入拒绝域（即拒绝 H_0 ）的概率：

$$g(p) = P_p(X \in W) = P_p(T \geq 1)$$

直接计算 $P(T \geq 1)$ 需要求 $P(T = 1) + P(T = 2) + P(T = 3)$ ，利用对立事件计算更为简便：

$$g(p) = 1 - P_p(T < 1) = 1 - P_p(T = 0)$$

代入二项分布公式，当 $k = 0$ 时：

$$P_p(T = 0) = \binom{3}{0} p^0 (1-p)^3 = (1-p)^3$$

因此，势函数为：

$$g(p) = 1 - (1-p)^3, \quad 0 < p < 1$$

4 求犯第一类错误的概率 α

犯第一类错误是指：原假设 H_0 为真，但我们拒绝了它。即当 $p = \frac{1}{2}$ 时，落入拒绝域的概率：

$$\alpha = g\left(\frac{1}{2}\right) = 1 - \left(1 - \frac{1}{2}\right)^3 = 1 - \left(\frac{1}{2}\right)^3 = 1 - \frac{1}{8} = \frac{7}{8}$$

5 求犯第二类错误的概率 β 及检验的势

犯第二类错误是指：备择假设 H_1 为真，但我们接受了 H_0 。即当 $p = \frac{3}{4}$ 时，未落入拒绝域的概率：

$$\beta = P_{p=3/4}(X \notin W) = 1 - g\left(\frac{3}{4}\right) = \frac{1}{64}$$

检验的势是指在 H_1 为真时, 正确拒绝 H_0 的概率:

$$\text{势} = g\left(\frac{3}{4}\right) = \frac{63}{64}$$

综上所述:

- 势函数: $g(p) = 1 - (1 - p)^3$
- 犯第一类错误的概率: $\alpha = \frac{7}{8}$
- 犯第二类错误的概率: $\beta = \frac{1}{64}$
- 检验的势: $\frac{63}{64}$

问题 29. 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, 其中方差 σ^2 已知, 考虑假设检验问题 $H_0: \mu = \mu_0, H_1: \mu = \mu_1 > \mu_0$. 取拒绝域 $W = \{(x_1, x_2, \dots, x_n) : \bar{x} \geq c\}$, 其中 $\mu_0 < c < \mu_1$.

(1) 求犯第一类错误的概率 $\alpha(\mu_0)$;

(2) 求犯第二类错误的概率 $\beta(\mu_1)$;

(3) 证明: 对固定的 n , 当 $\alpha(\mu_0)$ 减小时, $\beta(\mu_1)$ 增大, 而当 $\beta(\mu_1)$ 减小时, $\alpha(\mu_0)$ 增大;

(4) 证明: 对固定的 c , 当 n 充分大时, 可使 $\alpha(\mu_0)$ 和 $\beta(\mu_1)$ 任意小。

【解析】

已知 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, 且 σ^2 已知. 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 服从正态分布: $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, 即标准化变量 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$. 记 $\Phi(x)$ 为标准正态分布的分布函数。

(1) 求犯第一类错误的概率 $\alpha(\mu_0)$

犯第一类错误是指: 原假设 H_0 为真, 但拒绝了 H_0 . 当 H_0 为真时, $\mu = \mu_0$, 此时 $\bar{X} \sim N(\mu_0, \sigma^2/n)$. 拒绝域为 $W = \{\bar{x} \geq c\}$.

$$\begin{aligned} \alpha(\mu_0) &= P_{\mu_0}(\bar{X} \geq c) \\ &= P_{\mu_0}\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \geq \frac{c - \mu_0}{\sigma/\sqrt{n}}\right) \\ &= P\left(Z \geq \frac{c - \mu_0}{\sigma/\sqrt{n}}\right) \\ &= 1 - \Phi\left(\frac{c - \mu_0}{\sigma/\sqrt{n}}\right) \end{aligned}$$

(2) 求犯第二类错误的概率 $\beta(\mu_1)$

犯第二类错误是指：**备择假设 H_1 为真，但接受了 H_0** 。当 H_1 为真时， $\mu = \mu_1$ ，此时 $\bar{X} \sim N(\mu_1, \sigma^2/n)$ 。接受域为 $\bar{W} = \{\bar{x} < c\}$ 。

$$\begin{aligned}\beta(\mu_1) &= P_{\mu_1}(\bar{X} < c) \\ &= P_{\mu_1}\left(\frac{\bar{X} - \mu_1}{\sigma/\sqrt{n}} < \frac{c - \mu_1}{\sigma/\sqrt{n}}\right) \\ &= P\left(Z < \frac{c - \mu_1}{\sigma/\sqrt{n}}\right) \\ &= \Phi\left(\frac{c - \mu_1}{\sigma/\sqrt{n}}\right)\end{aligned}$$

(3) 证明

对于固定的样本量 n 和已知参数 σ, μ_0, μ_1 ，错误概率 $\alpha(\mu_0)$ 和 $\beta(\mu_1)$ 仅依赖于临界值 c 。由 (1) 和 (2) 的结果： $\alpha(c) = 1 - \Phi\left(\frac{c - \mu_0}{\sigma/\sqrt{n}}\right)$ ， $\beta(c) = \Phi\left(\frac{c - \mu_1}{\sigma/\sqrt{n}}\right)$

由于标准正态分布函数 $\Phi(x)$ 是单调严格递增函数：

- 对于 $\alpha(c)$ ：当 c 增大时， $\frac{c - \mu_0}{\sigma/\sqrt{n}}$ 增大， $\Phi(\cdot)$ 增大，故 $1 - \Phi(\cdot)$ 减小。即 $\alpha(c)$ 关于 c 单调递减。
- 对于 $\beta(c)$ ：当 c 增大时， $\frac{c - \mu_1}{\sigma/\sqrt{n}}$ 增大， $\Phi(\cdot)$ 增大。即 $\beta(c)$ 关于 c 单调递增。

结论：当 $\alpha(\mu_0)$ 减小时，意味着临界值 c 必须增大；而 c 的增大必然导致 $\beta(\mu_1)$ 增大。反之，当 $\beta(\mu_1)$ 减小时，意味着临界值 c 必须减小；而 c 的减小必然导致 $\alpha(\mu_0)$ 增大。证毕。

(4) 证明：对固定的 c ，当 n 充分大时，可使 $\alpha(\mu_0)$ 和 $\beta(\mu_1)$ 任意小

题目给定条件 $\mu_0 < c < \mu_1$ 。

- 对于 $\alpha(\mu_0)$ ：考察极限 $\lim_{n \rightarrow \infty} \alpha(\mu_0)$ 。令 $u_n = \frac{c - \mu_0}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(c - \mu_0)}{\sigma}$ 。因为 $c > \mu_0$ ，所以 $c - \mu_0 > 0$ 。当 $n \rightarrow \infty$ 时， $u_n \rightarrow +\infty$ 。

故： $\lim_{n \rightarrow \infty} \alpha(\mu_0) = \lim_{n \rightarrow \infty} [1 - \Phi(u_n)] = 1 - \Phi(+\infty) = 1 - 1 = 0$

- 对于 $\beta(\mu_1)$ ：考察极限 $\lim_{n \rightarrow \infty} \beta(\mu_1)$ 。令 $v_n = \frac{c - \mu_1}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(c - \mu_1)}{\sigma}$ 。因为 $c < \mu_1$ ，所以 $c - \mu_1 < 0$ 。当 $n \rightarrow \infty$ 时， $v_n \rightarrow -\infty$ 。

故： $\lim_{n \rightarrow \infty} \beta(\mu_1) = \lim_{n \rightarrow \infty} \Phi(v_n) = \Phi(-\infty) = 0$

综上所述，当 $n \rightarrow \infty$ 时， $\alpha(\mu_0) \rightarrow 0$ 且 $\beta(\mu_1) \rightarrow 0$ 。即当样本量 n 充分大时，两类错误的概率均可任意小。证毕。

问题 30 (单边检验). 某厂生产某种元件，其使用寿命不低于 1000 h 才合格。现从这批元件中随机抽取 25 件，其寿命均值 950 h。已知元件寿命服从标准差为 100 h 的正态分布。在显著性水平 $\alpha = 0.05$ 下，问这批元件是否合格？

【解析】**1 建立假设**

根据题意, 元件合格的标准是寿命不低于 1000 h。我们要检验这批元件是否合格, 通常将“合格”(即我们希望维持的现状或标准)设为原假设, 或者将“不合格”(我们需要发现的问题)设为备择假设。设元件寿命 $X \sim N(\mu, \sigma^2)$, 其中 $\sigma = 100$ 。建立单侧假设检验: $H_0: \mu \geq \mu_0$ vs $H_1: \mu < \mu_0$, $\mu_0 = 1000$

2 选取检验统计量

由于总体方差 σ^2 已知, 应选用 Z 检验。在 H_0 成立的边界条件 ($\mu = 1000$) 下, 统计量为: $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$

3 确定拒绝域

这是一个左侧检验 (因为 H_1 是 $\mu < 1000$)。对于显著性水平 $\alpha = 0.05$, 查标准正态分布表可得临界值 $z_\alpha = z_{0.05} = 1.645$ 。拒绝域为: $W = \{Z < -z_{0.05}\} = \{Z < -1.645\}$ 即: 如果计算出的 Z 值小于 -1.645 , 则拒绝原假设。

4 计算统计量的值

已知 $n = 25$, $\bar{x} = 950$, $\mu_0 = 1000$, $\sigma = 100$ 。代入公式计算: $Z = \frac{950 - 1000}{100/\sqrt{25}} = \frac{-50}{100/5} = \frac{-50}{20} = -2.5 < -1.645$, 统计量落入拒绝域 W 。所以在显著性水平 $\alpha = 0.05$ 下, 拒绝原假设 H_0 。

结论: 有充分的理由认为这批元件的平均寿命显著低于 1000 h, 即认为这批元件不合格。

问题 31 (双边检验). 设总体 $X \sim N(\mu, \sigma_0^2)$, 其中 σ_0^2 已知, μ 为未知参数, x_1, x_2, \dots, x_n 为来自总体 X 的简单样本, 考虑假设检验问题

$$H_0: \mu = \mu_0, \quad H_1: \mu \neq \mu_0$$

在显著性水平 α 下, 试求似然比检验。

【解析】**第一步: 写出似然函数**

设总体 $X \sim N(\mu, \sigma_0^2)$, 其中 σ_0^2 已知。样本 x_1, x_2, \dots, x_n 的似然函数为:

$$L(\mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left\{-\frac{(x_i - \mu)^2}{2\sigma_0^2}\right\} = (2\pi\sigma_0^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

参数空间为 $\Omega = \{\mu \mid -\infty < \mu < +\infty\}$ 。原假设对应的参数空间为 $\Omega_0 = \{\mu_0\}$

第二步: 求解全参数空间的极大似然估计

在全参数空间 Ω 中, 我们需要找到使 $L(\mu)$ 达到最大的 $\hat{\mu}$ 。观察似然函数 $L(\mu)$ 的表达式, 要使 $L(\mu)$ 最大, 等价于使指数部分的 $\sum_{i=1}^n (x_i - \mu)^2$ 最小。直接求导, 我们知道当 μ 取样本均值时, 该式取最小值。即全参数空间的极大似然估计为:

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

此时似然函数的最大值为：

$$\sup_{\mu \in \Omega} L(\mu) = L(\bar{x}) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right\}$$

第三步：求解 H_0 成立时的极大似然估计

在原假设 $H_0: \mu = \mu_0$ 成立的条件下，参数空间 Ω_0 只有唯一的值 μ_0 。因此，受限极大似然估计就是直接代入 μ_0 ：

$$\sup_{\mu \in \Omega_0} L(\mu) = L(\mu_0) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right\}$$

第四步：构造似然比统计量 λ

似然比统计量定义为 $\lambda = \frac{\sup_{\mu \in \Omega_0} L(\mu)}{\sup_{\mu \in \Omega} L(\mu)}$ 。代入上述结果：

$$\lambda = \frac{(2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right\}}{(2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right\}}$$

化简表达式：

$$\lambda = \exp \left\{ -\frac{1}{2\sigma_0^2} \left[\sum_{i=1}^n (x_i - \mu_0)^2 - \sum_{i=1}^n (x_i - \bar{x})^2 \right] \right\}$$

利用恒等式 $\sum_{i=1}^n (x_i - \mu_0)^2 = \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu_0)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2$ (交叉项为 0)，指数部分的方括号内可以化简为：

$$\sum_{i=1}^n (x_i - \mu_0)^2 - \sum_{i=1}^n (x_i - \bar{x})^2 = n(\bar{x} - \mu_0)^2$$

因此，似然比统计量为：

$$\lambda = \exp \left\{ -\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2} \right\}$$

第五步：确定拒绝域

似然比检验法则为：当 $\lambda \leq c$ 时拒绝 H_0 ，其中 c ($0 < c < 1$) 是由显著性水平 α 确定的临界值。不等式 $\lambda \leq c$ 等价于：

$$\exp \left\{ -\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2} \right\} \leq c$$

两边取自然对数：

$$-\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2} \leq \ln c$$

整理得：

$$\frac{n(\bar{x} - \mu_0)^2}{\sigma_0^2} \geq -2 \ln c$$

两边开方（注意绝对值）：

$$\left| \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma_0} \right| \geq \sqrt{-2 \ln c}$$

令 $k = \sqrt{-2 \ln c}$ ，则拒绝域形式为：

$$\left| \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}} \right| \geq k$$

第六步：利用统计量的分布确定临界值

在 H_0 成立的条件下，统计量 $Z = \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}$ 服从标准正态分布 $N(0, 1)$ 。根据给定的显著性水平 α ，我们需要满足：

$$P_{H_0}(\text{拒绝 } H_0) = P\left(\left| \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}} \right| \geq k\right) = \alpha$$

由于 $Z \sim N(0, 1)$ ，上述概率即为标准正态分布的双侧尾部概率。因此，临界值 k 应为标准正态分布的上侧 $\alpha/2$ 分位数 $z_{\alpha/2}$ （即满足 $P(Z > z_{\alpha/2}) = \alpha/2$ ）。

结论

该问题的似然比检验的拒绝域为：

$$W = \left\{ (x_1, \dots, x_n) : \left| \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}} \right| \geq z_{\alpha/2} \right\}$$

其中 $z_{\alpha/2}$ 是标准正态分布的上侧 $\alpha/2$ 分位数。

问题 32 (了解). 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(\mu_0, \sigma^2)$ 的简单样本，其中 μ_0 已知， σ^2 是未知参数，对给定的水平 α ，试分别求下列假设检验问题的一致最大势检验 UMPT：

$$(1) H_0 : \sigma^2 \geq \sigma_0^2, \quad H_1 : \sigma^2 < \sigma_0^2;$$

$$(2) H_0 : \sigma^2 \leq \sigma_1^2 \text{ 或 } \sigma^2 \geq \sigma_2^2, \quad H_1 : \sigma_1^2 < \sigma^2 < \sigma_2^2.$$

【解析】

一、一致最大势检验 (UMPT) 的定义

设样本 X 的分布族为 $\{f(x; \theta) : \theta \in \Theta\}$ ，考虑假设检验问题：

$$H_0 : \theta \in \Theta_0 \quad \text{vs} \quad H_1 : \theta \in \Theta_1$$

若存在一个检验 $\phi^*(x)$ ，满足以下两个条件：

1 水平条件：对任意 $\theta \in \Theta_0$ ，有 $E_\theta[\phi^*(X)] \leq \alpha$ ；

2 最大势条件：对于任意其他满足水平 α 的检验 $\phi(x)$ ，以及任意 $\theta \in \Theta_1$ ，都有

$$E_\theta[\phi^*(X)] \geq E_\theta[\phi(X)]$$

则称 $\phi^*(x)$ 为该假设检验问题在显著性水平 α 下的一致最大势检验 (UMPT)。

二、准备工作：写出似然函数与充分统计量

样本 x_1, \dots, x_n 来自 $N(\mu_0, \sigma^2)$, 且 μ_0 已知。样本的联合概率密度函数为:

$$\begin{aligned} L(\sigma^2; x) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x_i - \mu_0)^2}{2\sigma^2} \right\} \\ &= (2\pi)^{-\frac{n}{2}} (\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right\} \end{aligned}$$

这是属于单参数指数族分布。令 $T(x) = \sum_{i=1}^n (x_i - \mu_0)^2$, $\theta = \sigma^2$ 。显然 $T(x)$ 是 σ^2 的充分统计量。我们知道 $\frac{x_i - \mu_0}{\sigma} \sim N(0, 1)$, 故

$$\frac{T(x)}{\sigma^2} = \sum_{i=1}^n \left(\frac{x_i - \mu_0}{\sigma} \right)^2 \sim \chi^2(n)$$

三、检验问题 (1) 的求解

1 问题描述

$$H_0: \sigma^2 \geq \sigma_0^2 \quad \text{vs} \quad H_1: \sigma^2 < \sigma_0^2$$

2 验证单调似然比 (MLR) 性质

考虑似然函数关于统计量 $T(x)$ 的结构。对于任意 $\sigma_1^2 < \sigma_2^2$, 考察似然比:

$$\frac{L(\sigma_2^2; x)}{L(\sigma_1^2; x)} = \frac{(\sigma_2^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_2^2} T(x) \right\}}{(\sigma_1^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_1^2} T(x) \right\}} = \left(\frac{\sigma_2^2}{\sigma_1^2} \right)^{-n/2} \exp \left\{ \left(\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2} \right) T(x) \right\}$$

由于 $\sigma_1^2 < \sigma_2^2$, 则 $\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2} > 0$ 。因此, 该似然比是统计量 $T(x)$ 的严格单调递增函数。即分布族 $\{P_{\sigma^2}\}$ 具有关于统计量 $T(x)$ 的单调似然比性质 (MLR)。

3 利用 Karlin-Rubin 定理构造 UMPT

根据 Karlin-Rubin 定理, 对于单边检验问题 $H_0: \theta \geq \theta_0$ vs $H_1: \theta < \theta_0$, 若似然比关于 $T(x)$ 单调递增, 则 UMPT 的拒绝域形式为 $T(x) \leq C$ 。

具体地, 检验函数为:

$$\phi(x) = \begin{cases} 1, & T(x) < C \\ \gamma, & T(x) = C \\ 0, & T(x) > C \end{cases}$$

由于 $T(x)$ 是连续型随机变量, 边界处概率为 0, 可取 $\gamma = 0$ 。拒绝域形式为 $W = \{x: T(x) \leq C\}$ 。

4 确定临界值 C

临界值 C 由显著性水平 α 在边界点 σ_0^2 处确定:

$$P_{\sigma_0^2}(T(x) \leq C) = \alpha$$

在 H_0 的边界 $\sigma^2 = \sigma_0^2$ 处, $\frac{T(x)}{\sigma_0^2} \sim \chi^2(n)$ 。因此:

$$P\left(\frac{T(x)}{\sigma_0^2} \leq \frac{C}{\sigma_0^2}\right) = \alpha$$

这意味着 $\frac{C}{\sigma_0^2}$ 应当是 $\chi^2(n)$ 分布的下侧 α 分位数。记 $\chi_\alpha^2(n)$ 为 $\chi^2(n)$ 的下侧 α 分位数 (即累积概率为 α 的点)。则 $\frac{C}{\sigma_0^2} = \chi_\alpha^2(n) \implies C = \sigma_0^2 \chi_\alpha^2(n)$ 。

5 结论 (1)

该假设检验问题的一致最大势检验 (UMPT) 拒绝域为:

$$W = \left\{ (x_1, \dots, x_n) : \sum_{i=1}^n (x_i - \mu_0)^2 \leq \sigma_0^2 \chi_\alpha^2(n) \right\}$$

四、检验问题 (2) 的求解

1 问题描述

$$H_0 : \sigma^2 \leq \sigma_1^2 \text{ 或 } \sigma^2 \geq \sigma_2^2 \quad \text{vs} \quad H_1 : \sigma_1^2 < \sigma^2 < \sigma_2^2$$

其中 $\sigma_1^2 < \sigma_2^2$ 。这是一个双边假设检验问题 (中间区域为备择假设)。

2 验证 UMPT 存在的条件

这是关于单参数指数族分布的双边检验。指数族分布密度形式为 $f(x; \theta) = C(\theta)e^{Q(\theta)T(x)}h(x)$ 。在本题中, 令 $\theta = -\frac{1}{2\sigma^2}$ (自然参数), 则 $Q(\theta) = \theta$, $T(x) = \sum (x_i - \mu_0)^2$ 。由于 $Q(\theta)$ 是严格单调递增函数, 且分布族具有 MLR 性质。对于形如 $H_0 : \theta \leq \theta_1$ 或 $\theta \geq \theta_2$ vs $H_1 : \theta_1 < \theta < \theta_2$ 的检验问题, 存在 UMPT, 其拒绝域形式为:

$$C_1 \leq T(x) \leq C_2$$

3 构造 UMPT

检验函数的形式为:

$$\phi(x) = \begin{cases} 1, & C_1 \leq T(x) \leq C_2 \\ 0, & \text{其他} \end{cases}$$

即当统计量 $T(x)$ 落在区间 $[C_1, C_2]$ 内时拒绝 H_0 。

4 确定临界值 C_1, C_2

临界值 C_1, C_2 由水平 α 在两个边界点 σ_1^2 和 σ_2^2 处确定:

$$\begin{cases} E_{\sigma_1^2}[\phi(X)] = P_{\sigma_1^2}(C_1 \leq T(X) \leq C_2) = \alpha \\ E_{\sigma_2^2}[\phi(X)] = P_{\sigma_2^2}(C_1 \leq T(X) \leq C_2) = \alpha \end{cases}$$

利用 $Y = \frac{T(X)}{\sigma^2} \sim \chi^2(n)$ 进行标准化: 在 $\sigma^2 = \sigma_1^2$ 时, 概率为:

$$P\left(\frac{C_1}{\sigma_1^2} \leq \frac{T(X)}{\sigma_1^2} \leq \frac{C_2}{\sigma_1^2}\right) = \alpha$$

令 $F_{\chi^2(n)}(y)$ 为自由度为 n 的卡方分布的累积分布函数, 则方程组为:

$$\begin{cases} F_{\chi^2(n)}\left(\frac{C_2}{\sigma_1^2}\right) - F_{\chi^2(n)}\left(\frac{C_1}{\sigma_1^2}\right) = \alpha \\ F_{\chi^2(n)}\left(\frac{C_2}{\sigma_2^2}\right) - F_{\chi^2(n)}\left(\frac{C_1}{\sigma_2^2}\right) = \alpha \end{cases}$$

5 结论 (2)

该假设检验问题的一致最大势检验 (UMPT) 拒绝域为:

$$W = \left\{ (x_1, \dots, x_n) : C_1 \leq \sum_{i=1}^n (x_i - \mu_0)^2 \leq C_2 \right\}$$

其中常数 C_1, C_2 由方程组 $\begin{cases} P_{\sigma_1^2}(C_1 \leq T \leq C_2) = \alpha \\ P_{\sigma_2^2}(C_1 \leq T \leq C_2) = \alpha \end{cases}$ 唯一确定。

问题 33 (了解). 设总体 $X \sim B(1, p), 0 < p < 1$, x_1, x_2, \dots, x_n 为来自总体 X 的简单样本。对给定的水平 α , 试求假设检验问题 $H_0: p = p_0, H_1: p \neq p_0$ 的一致最大势无偏检验 UMPUT。

【解析】

一、一致最大势无偏检验 (UMPUT) 的定义

对于参数 θ 的假设检验问题 $H_0: \theta \in \Theta_0$ vs $H_1: \theta \in \Theta_1$, 若检验 ϕ^* 满足以下条件:

1 无偏性:

$$\begin{cases} E_\theta[\phi^*(X)] \leq \alpha, & \forall \theta \in \Theta_0 \\ E_\theta[\phi^*(X)] \geq \alpha, & \forall \theta \in \Theta_1 \end{cases}$$

2 一致最大势: 在所有满足无偏性的检验类 \mathcal{C}_α 中, ϕ^* 具有最大的势, 即对于任意 $\phi \in \mathcal{C}_\alpha$, 有:

$$E_\theta[\phi^*(X)] \geq E_\theta[\phi(X)], \quad \forall \theta \in \Theta_1$$

则称 ϕ^* 为水平 α 的一致最大势无偏检验 (UMPUT)。

二、识别指数族分布与充分统计量

总体 $X \sim B(1, p)$, 其概率分布律为 $P(X = x) = p^x(1-p)^{1-x} (x = 0, 1)$ 。样本 x_1, \dots, x_n 的联合分布律为:

$$\begin{aligned} L(p; x) &= \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} \\ &= p^{\sum x_i} (1-p)^{n-\sum x_i} \\ &= (1-p)^n \left(\frac{p}{1-p} \right)^{\sum x_i} \\ &= (1-p)^n \exp \left\{ \left(\ln \frac{p}{1-p} \right) \sum_{i=1}^n x_i \right\} \end{aligned}$$

令 $\theta = \ln \frac{p}{1-p}$ (自然参数), $T(x) = \sum_{i=1}^n x_i$ 。由于 θ 是 p 的严格单调递增函数, 且 $L(p; x)$ 具有单参数指数族的形式, 故 $T(x) = \sum_{i=1}^n x_i$ 是 p 的充分统计量。统计量 T 服从二项分布 $B(n, p)$ 。

三、构造 UMPUT

对于单参数指数族分布的双侧检验问题:

$$H_0: p = p_0 \quad \text{vs} \quad H_1: p \neq p_0$$

根据 UMPUT 的构造定理, 检验函数 $\phi(t)$ 应当具有如下形式 (“双边拒绝, 中间接受”):

$$\phi(t) = \begin{cases} 1, & t < C_1 \text{ 或 } t > C_2 \\ \gamma_1, & t = C_1 \\ \gamma_2, & t = C_2 \\ 0, & C_1 < t < C_2 \end{cases}$$

其中 C_1, C_2 是整数临界值, $0 \leq \gamma_1, \gamma_2 \leq 1$ 是边界随机化概率。

四、确定常数的方程组

常数 $C_1, C_2, \gamma_1, \gamma_2$ 由无偏性的边界条件 (即在 $p = p_0$ 处的性质) 确定。根据定理, UMPUT 必须满足以下两个条件 (类似于在 p_0 处的一阶导数和函数值条件):

1 水平条件: 在 H_0 成立时, 拒绝概率为 α 。

$$E_{p_0}[\phi(T)] = \alpha$$

2 无偏性引出的导数条件: 在 p_0 处势函数的导数为 0 (意味着势函数在 p_0 处取最小值 α)。

$$E_{p_0}[T\phi(T)] = \alpha E_{p_0}[T] = np_0\alpha$$

将 $\phi(t)$ 的具体形式代入上述两个条件, 得到方程组:

$$\begin{cases} \sum_{k=0}^n \phi(k) P_{p_0}(T = k) = \alpha \\ \sum_{k=0}^n k \phi(k) P_{p_0}(T = k) = np_0\alpha \end{cases}$$

展开为具体表达式 (记 $b(k; n, p_0) = \binom{n}{k} p_0^k (1-p_0)^{n-k}$):

$$\begin{cases} P(T < C_1) + \gamma_1 P(T = C_1) + \gamma_2 P(T = C_2) + P(T > C_2) = \alpha \\ \sum_{t \in R} t \cdot b(t; n, p_0) + C_1 \gamma_1 b(C_1; n, p_0) + C_2 \gamma_2 b(C_2; n, p_0) = np_0\alpha \end{cases}$$

其中第一式中的概率 P 均基于 $B(n, p_0)$ 计算, R 表示确定的拒绝域 $\{t < C_1\} \cup \{t > C_2\}$ 。

五、结论

该假设检验问题的一致最大势无偏检验 (UMPUT) 为:

$$\phi(x) = \begin{cases} 1, & \sum x_i < C_1 \text{ 或 } \sum x_i > C_2 \\ \gamma_1, & \sum x_i = C_1 \\ \gamma_2, & \sum x_i = C_2 \\ 0, & C_1 < \sum x_i < C_2 \end{cases}$$

其中常数 $C_1, C_2, \gamma_1, \gamma_2$ 由方程组

$$\begin{cases} E_{p_0}[\phi(T)] = \alpha \\ E_{p_0}[T\phi(T)] = np_0\alpha \end{cases}$$

唯一确定。

问题 34 (了解). 设总体 $X \sim B(1, p)$ ($0 < p < 1$), x_1, x_2, \dots, x_n 为来自总体 X 的简单样本。(1) 对假设检验问题: $H_0: p \leq 0.1$ vs $H_1: p > 0.1$, 给定显著性水平 $\alpha = 0.05$, 构造该问题的一致最优势检验 (UMPT); (2) 当 $n = 10$ 时, 给出具体的检验函数; (3) 根据 (2) 中的检验函数, 判断以下两种情况是否拒绝原假设: (a) $\sum_{i=1}^{10} x_i \geq 2$; (b) $\sum_{i=1}^{10} x_i < 2$ 。

【解析】

一、构建一致最优势检验 (UMPT) 的理论推导

1 识别指数族分布与充分统计量

设总体 $X \sim B(1, p)$, 样本 x_1, \dots, x_n 的联合概率函数 (似然函数) 为:

$$\begin{aligned} L(p; x) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\ &= p^{\sum x_i} (1-p)^{n-\sum x_i} \\ &= (1-p)^n \left(\frac{p}{1-p} \right)^{\sum x_i} \\ &= (1-p)^n \exp \left\{ \ln \left(\frac{p}{1-p} \right) \sum_{i=1}^n x_i \right\} \end{aligned}$$

这是一个单参数指数族分布。令 $T(x) = \sum_{i=1}^n x_i$, 它是参数 p 的充分统计量。令 $Q(p) = \ln \left(\frac{p}{1-p} \right)$, 因为 $Q(p)$ 是关于 p 的严格单调递增函数, 所以该分布族关于统计量 $T(x)$ 具有单调似然比 (MLR) 性质。

2 根据 Karlin-Rubin 定理构造 UMPT

假设检验问题为 $H_0: p \leq 0.1$ vs $H_1: p > 0.1$ 。根据 Karlin-Rubin 定理, 对于 $H_1: p > p_0$ 的单边检验, 存在一致最优势检验 (UMPT), 其拒绝域形式为 $T(x) > C$ 。

由于 $T(x) \sim B(n, p)$ 是离散型随机变量, 为了使检验的实际水平严格等于 α , 我们需要引入随机化检验函数 $\phi(x)$:

$$\phi(x) = \begin{cases} 1, & T(x) > C \\ \gamma, & T(x) = C \\ 0, & T(x) < C \end{cases}$$

其中, 临界值 C (整数) 和随机化概率 $\gamma \in [0, 1)$ 由显著性水平 α 在边界点 $p_0 = 0.1$ 处确定:

$$E_{p_0}[\phi(X)] = P_{p_0}(T > C) + \gamma P_{p_0}(T = C) = \alpha$$

二、当 $n = 10, \alpha = 0.05$ 时的具体计算

当 $n = 10, p_0 = 0.1$ 时, 统计量 $T \sim B(10, 0.1)$ 。我们需要确定 C 和 γ 使得 $E_{0.1}[\phi] = 0.05$ 。

1 计算 $B(10, 0.1)$ 的概率分布

概率质量函数为 $P(T = k) = \binom{10}{k}(0.1)^k(0.9)^{10-k}$ 。

- $P(T = 0) = \binom{10}{0}(0.9)^{10} \approx 0.3487$
- $P(T = 1) = \binom{10}{1}(0.1)(0.9)^9 \approx 0.3874$
- $P(T = 2) = \binom{10}{2}(0.1)^2(0.9)^8 = 45 \times 0.01 \times 0.430467 \approx 0.1937$
- $P(T = 3) = \binom{10}{3}(0.1)^3(0.9)^7 = 120 \times 0.001 \times 0.478297 \approx 0.0574$
- $P(T = 4) = \binom{10}{4}(0.1)^4(0.9)^6 = 210 \times 0.0001 \times 0.531441 \approx 0.0112$

2 确定临界值 C

我们需要找到满足 $P(T > C) \leq 0.05$ 的最小整数 C 。计算上侧尾部概率:

- $P(T \geq 4) = 1 - P(T \leq 3) = 1 - (0.3487 + 0.3874 + 0.1937 + 0.0574) = 1 - 0.9872 = 0.0128$
- $P(T \geq 3) = P(T \geq 4) + P(T = 3) = 0.0128 + 0.0574 = 0.0702$

观察发现: $P(T > 2) = P(T \geq 3) = 0.0702 > 0.05$ $P(T > 3) = P(T \geq 4) = 0.0128 < 0.05$
因此, 临界值应取 $C = 3$ 。

3 确定随机化概率 γ

代入方程 $P(T > 3) + \gamma P(T = 3) = 0.05$:

$$\begin{aligned} 0.0128 + \gamma \times 0.0574 &= 0.05 \\ \gamma &= \frac{0.05 - 0.0128}{0.0574} = \frac{0.0372}{0.0574} \approx 0.648 \end{aligned}$$

4 写出检验函数

该问题的一致最优势检验函数为：

$$\phi(x_1, \dots, x_{10}) = \begin{cases} 1, & \sum x_i > 3 \quad (\text{即 } \sum x_i \geq 4) \\ 0.648, & \sum x_i = 3 \\ 0, & \sum x_i < 3 \end{cases}$$

三、判断是否拒绝原假设

根据上述检验函数 $\phi(x)$ ，对以下情况进行判断：

(a) 当 $\sum_{i=1}^{10} x_i \geq 2$ 时：这里需要根据具体的观测值来判断。

- 假如观测值 $\sum x_i = 2$ ：由于 $2 < 3$ ，根据检验函数 $\phi(2) = 0$ ，此时接受原假设（不拒绝 H_0 ）。
- 即使题目意指“只要落在 ≥ 2 的区域”，我们发现 $P_{H_0}(T \geq 2) \approx 0.26 > 0.05$ ，该区域不能作为显著性水平为 0.05 的拒绝域。
- **结论**：对于观测值等于 2 的情况，不拒绝原假设。

(b) 当 $\sum_{i=1}^{10} x_i < 2$ 时：这意味着观测值 $\sum x_i$ 为 0 或 1。

- 由于 $0 < 3$ 且 $1 < 3$ ，根据检验函数 $\phi(x) = 0$ ，此时接受原假设（不拒绝 H_0 ）。
- **结论**：不拒绝原假设。

1.7 贝叶斯分析

贝叶斯推断的核心是利用样本信息修正先验信息。贝叶斯学派认为，统计推断的过程实际上是信息更新的过程。随着数据量的增加，先验的影响力会越来越小

1. 初始信息：先验分布 $\pi(\theta)$ （试验前的认识）。
2. 新信息：样本信息 x ，通过似然函数 $L(\theta|x) = f(x|\theta)$ 体现。
3. 综合信息：后验分布 $\pi(\theta|x)$ （试验后的认识）。

根据贝叶斯公式，三者的关系为： $\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int_{\Theta} f(x|\theta)\pi(\theta)d\theta} \propto L(\theta|x)\pi(\theta)$ ，我们将 $L(\theta|x)\pi(\theta)$ 称为后验分布的核 (Kernel)，分母 $\int_{\Theta} f(x|\theta)\pi(\theta)d\theta$ 称为边缘概率。

连续型参数：

$$\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int_{\Theta} f(x|\theta)\pi(\theta)d\theta} \propto L(\theta;x)\pi(\theta) \quad (1.1)$$

离散型参数：若参数空间 $\Theta = \{\theta_1, \theta_2, \dots, \theta_k\}$ 是离散的，先验概率为 $P(\theta_i)$ ，则后验概率为

$$P(\theta_i|x) = \frac{P(x|\theta_i)P(\theta_i)}{\sum_{j=1}^k P(x|\theta_j)P(\theta_j)} \quad (1.2)$$

其中 $P(x|\theta_i)$ 是在参数取 θ_i 时观察到样本 x 的概率。

贝叶斯估计基本步骤

1. 确定参数 θ 的先验分布 $p(\theta)$

2. 由样本集 $D = \{x_1, x_2, \dots, x_N\}$ 求出样本联合分布 $p(D|\theta)$:

$$p(D|\theta) = \prod_{n=1}^N p(x_n|\theta)$$

3. 利用贝叶斯公式, 求 θ 的后验分布:

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{\int_{\phi} p(D|\theta)p(\theta)d\theta}$$

4. 求出贝叶斯估计:

$$\theta^* = \int_{\phi} \theta p(\theta|D)d\theta$$

1.7.1 常见先验分布

1. 贝塔分布 (Beta Distribution)

典型场景: 常作为二项分布或伯努利分布中成功概率 p 的先验分布。

定义: 若 $X \sim \text{Beta}(\alpha, \beta)$, 其概率密度函数为:

$$f(x; \alpha, \beta) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1$$

其中 $\alpha, \beta > 0$ 是超参数, $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ 。对 $n \in N^*$, $\Gamma(n) = (n-1)!$

统计量: 期望 $E[X] = \frac{\alpha}{\alpha+\beta}$, 方差 $\text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$

特例: 当 $\alpha = 1, \beta = 1$ 时, 即为均匀分布 $U(0, 1)$, 表示无信息先验。此时, 概率密度函数为 $f(x; \alpha, \beta) = 1$

2. 伯努利分布 (Bernoulli Distribution)

定义: 若随机变量 X 只取 0 或 1 两个值, 且取 1 的概率为 p , 取 0 的概率为 $1-p$, 则称 X 服从参数为 p 的伯努利分布 (或 0-1 分布), 记作 $X \sim \text{Bern}(p)$ 。

概率质量函数: $f(x; p) = p^x(1-p)^{1-x}$, $x \in \{0, 1\}$

统计量: 期望 $E[X] = p$, 方差 $\text{Var}(X) = p(1-p)$

3. 二项分布 (Binomial Distribution)

定义：做 n 次独立的伯努利试验，设每次试验成功的概率为 p ，则 n 次试验中成功的总次数 X 服从二项分布，记作 $X \sim \text{Bin}(n, p)$ 。

概率质量函数： $f(k; n, p) = P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$ ， $k = 0, 1, \dots, n$ ，其中 $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ 。

统计量：期望 $E[X] = np$ ，方差 $\text{Var}(X) = np(1-p)$

4. 正态分布 (Normal Distribution)

典型场景：当方差 σ^2 已知时，常作为正态分布均值 μ 的先验分布。

定义：若 $X \sim N(\mu_0, \tau^2)$ ，其概率密度函数为： $f(x; \mu_0, \tau^2) = \frac{1}{\sqrt{2\pi}\tau} \exp\left\{-\frac{(x-\mu_0)^2}{2\tau^2}\right\}$ ， $-\infty < x < \infty$

共轭性：已知 σ^2 ，正态总体的均值 μ 在正态先验下，其后验分布仍为正态分布。

5. 几何分布 (Geometric Distribution)

进行一系列独立重复的伯努利试验，每次试验成功概率为 p ， X 表示首次成功前的失败次数， X 服从几何分布： $P(X = k|p) = (1-p)^k p$ ， $k = 0, 1, 2, \dots$

统计量：期望 $E[X] = \frac{1-p}{p}$ ，方差 $\text{Var}(X) = \frac{1-p}{p^2}$

1.7.2 损失函数与贝叶斯估计

贝叶斯估计量 $\hat{\theta}_B$ 取决于所选用的损失函数 $L(\theta, \delta)$ ，目标是最小化后验期望损失 (贝叶斯风险)。

平方损失函数

- 损失函数： $L(\theta, \delta) = (\theta - \delta)^2$ 。
- 贝叶斯估计：后验分布的均值。

$$\hat{\theta}_B = E(\theta|X) \quad (1.3)$$

0-1 损失函数

- 损失函数： $L(\theta, \delta) = \begin{cases} 0, & |\theta - \delta| \leq \epsilon \\ 1, & |\theta - \delta| > \epsilon \end{cases}$ (极限情况)。
- 贝叶斯估计：最大后验估计。

$$\hat{\theta}_B = \arg \max_{\theta} \pi(\theta|X) \quad (1.4)$$

对于离散型参数，即选取后验概率最大的那个 θ 值。

绝对损失函数

- **损失函数**: $L(\theta, \delta) = |\theta - \delta|$ 。
- **贝叶斯估计**: 后验分布的中位数。

1.7.3 贝叶斯区间估计与估计评价

贝叶斯可信区间

对于给定的置信水平 $1 - \alpha$, 贝叶斯可信区间 $[a, b]$ 满足:

$$P(a \leq \theta \leq b|x) \geq 1 - \alpha \quad (1.5)$$

通常采用等尾可信区间:

$$\int_{-\infty}^a \pi(\theta|x)d\theta = \alpha/2, \quad \int_b^{+\infty} \pi(\theta|x)d\theta = \alpha/2$$

即利用后验分布的分位数。对于正态后验 $N(\mu_n, \sigma_n^2)$, 区间为 $[\mu_n - z_{\alpha/2}\sigma_n, \mu_n + z_{\alpha/2}\sigma_n]$ 。

估计量的评价

- **均方误差 (MSE)**: $MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [Bias(\hat{\theta})]^2$ 。比较两个估计量的 MSE, MSE 越小越优。
- **费雪信息量与 CR 下界**:

$$I(\theta) = E \left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2} \right]$$

有效估计量的方差应达到 Cramer-Rao 下界 $\frac{1}{nI(\theta)}$ 。

1.7.4 练习题

问题 35. 设总体 $X \sim N(\mu, 1)$, 参数 $\mu \sim N(0, 1)$, X_1, \dots, X_n 是来自于总体 X 的样本, 并且损失函数为 $\lambda(\mu, d) = (\mu - d)^2$, 求参数 μ 的贝叶斯估计量 $\hat{\mu}$ 。

【解析】

这是一个标准的正态-正态贝叶斯估计问题。我们需要先求出后验分布, 然后根据平方损失函数的性质求出贝叶斯估计。

第一步: 写出先验分布

已知参数 $\mu \sim N(0, 1)$, 其先验概率密度函数为:

$$\pi(\mu) = \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{\mu^2}{2} \right\} \propto \exp \left\{ -\frac{\mu^2}{2} \right\}$$

第二步：写出似然函数

由于总体 $X \sim N(\mu, 1)$ ，其概率密度函数为 $f(x|\mu) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2}\right\}$ 。样本的似然函数为：

$$L(\mu; x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(x_i - \mu)^2}{2}\right\} \propto \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

利用恒等式 $\sum (x_i - \mu)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2$ ，关于 μ 的核心部分为：

$$L(\mu; x) \propto \exp\left\{-\frac{n(\bar{x} - \mu)^2}{2}\right\}$$

第三步：求解后验分布

根据贝叶斯公式 $\pi(\mu|x) \propto L(\mu; x)\pi(\mu)$ ，将似然函数与先验密度相乘：

$$\begin{aligned} \pi(\mu|x) &\propto \exp\left\{-\frac{n(\bar{x} - \mu)^2}{2}\right\} \cdot \exp\left\{-\frac{\mu^2}{2}\right\} \\ &= \exp\left\{-\frac{1}{2} [n(\mu^2 - 2\bar{x}\mu + \bar{x}^2) + \mu^2]\right\} \\ &= \exp\left\{-\frac{1}{2} [(n+1)\mu^2 - 2n\bar{x}\mu + n\bar{x}^2]\right\} \end{aligned}$$

我们需要配方成关于 μ 的正态分布形式 $-\frac{(\mu - \mu_n)^2}{2\sigma_n^2}$ 。指数部分关于 μ 的项为 $(n+1)\mu^2 - 2n\bar{x}\mu$ 。

$$(n+1)(\mu^2 - \frac{2n\bar{x}}{n+1}\mu) = (n+1)\left(\mu - \frac{n\bar{x}}{n+1}\right)^2 + C$$

忽略常数 C ，我们得到后验分布的核：

$$\pi(\mu|x) \propto \exp\left\{-\frac{n+1}{2} \left(\mu - \frac{n\bar{x}}{n+1}\right)^2\right\}$$

这正是正态分布 $N(\mu_n, \sigma_n^2)$ 的形式，正态分布标准核为 $\pi(\mu|x) = \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\}$ ，因此：

$$\text{后验均值 } \mu_n = \frac{n\bar{x}}{n+1}, \quad \text{后验方差 } \sigma_n^2 = \frac{1}{n+1}$$

即 $\mu|x \sim N\left(\frac{n\bar{x}}{n+1}, \frac{1}{n+1}\right)$ 。

第四步：根据损失函数求贝叶斯估计

在平方损失下，贝叶斯估计量 $\hat{\mu}$ 为后验分布的期望（均值）。因此：

$$\hat{\mu} = E(\mu|x) = \frac{n\bar{X}}{n+1}$$

问题 36. 设 X_1, \dots, X_n 为总体 $X \sim B(10, p)$ 的样本， $0 < p < 1$ 。

(1) 试证 $T_1 = \frac{1}{10}\bar{X}$ 是参数 p 的有效估计量，并求相应的信息量 $I(p)$ ；

(2) 如果 $p \sim U[0, 1]$, 在平方损失下, 求参数 p 的贝叶斯估计量 T_2 ;

(3) 试比较两个估计量 T_1 和 T_2 的优劣。

【解析】

(1) 证明 T_1 是有效估计量并求信息量 $I(p)$ 。

必须先验证无偏性, 再验证方差达到 CRLB。

第一步: 计算 T_1 的期望与方差。 已知总体 $X \sim B(10, p)$, 则二项分布单个样本 X_i 的期望与方差为:

$$E(X_i) = 10p, \quad \text{Var}(X_i) = 10p(1-p)$$

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望与方差为:

$$E(\bar{X}) = 10p, \quad \text{Var}(\bar{X}) = \frac{10p(1-p)}{n}$$

对于估计量 $T_1 = \frac{1}{10} \bar{X}$:

• **首先证明无偏性:**

$$E(T_1) = E\left(\frac{1}{10} \bar{X}\right) = \frac{1}{10} E(\bar{X}) = \frac{1}{10} \cdot 10p = p$$

所以 T_1 是参数 p 的无偏估计量。

• **方差:**

$$\text{Var}(T_1) = \text{Var}\left(\frac{1}{10} \bar{X}\right) = \frac{1}{100} \text{Var}(\bar{X}) = \frac{1}{100} \cdot \frac{10p(1-p)}{n} = \frac{p(1-p)}{10n}$$

第二步: 计算 Fisher 信息量。 设 X 为总体的一个观测值, 其概率质量函数为:

$$f(x; p) = \binom{10}{x} p^x (1-p)^{10-x}, \quad x = 0, 1, \dots, 10$$

对数似然函数为:

$$\ln f(x; p) = \ln \binom{10}{x} + x \ln p + (10-x) \ln(1-p)$$

求一阶导数:

$$\frac{\partial \ln f}{\partial p} = \frac{x}{p} - \frac{10-x}{1-p}$$

求二阶导数:

$$\frac{\partial^2 \ln f}{\partial p^2} = -\frac{x}{p^2} - \frac{10-x}{(1-p)^2}$$

单个样本的费雪信息量 $I_1(p)$ 为:

$$\begin{aligned} I_1(p) &= -E \left[\frac{\partial^2 \ln f}{\partial p^2} \right] = E \left[\frac{X}{p^2} + \frac{10-X}{(1-p)^2} \right] \\ &= \frac{10p}{p^2} + \frac{10-10p}{(1-p)^2} = \frac{10}{p} + \frac{10}{1-p} \\ &= \frac{10}{p(1-p)} \end{aligned}$$

样本容量为 n 的样本总费雪信息量 $I(p)$ 为:

$$I(p) = nI_1(p) = \frac{10n}{p(1-p)}$$

第三步: 比较 $Var(\hat{\theta})$ 是否等于 CRLB。根据 Cramér-Rao 不等式, 参数 p 的任何无偏估计量 \hat{p} 的方差满足下界:

$$Var(\hat{p}) \geq \frac{1}{I(p)} = \frac{1}{\frac{10n}{p(1-p)}} = \frac{p(1-p)}{10n}$$

对比 T_1 的方差:

$$Var(T_1) = \frac{p(1-p)}{10n}$$

由于 $Var(T_1)$ 达到了 Cramér-Rao 下界, 因此 T_1 是参数 p 的有效估计量。

(2) 求参数 p 的贝叶斯估计量 T_2

第一步: 写出似然函数和先验分布。样本 $x = (x_1, \dots, x_n)$ 的似然函数为:

$$\begin{aligned} L(p; x) &= \prod_{i=1}^n \binom{10}{x_i} p^{x_i} (1-p)^{10-x_i} \\ &\propto p^{\sum_{i=1}^n x_i} (1-p)^{10n - \sum_{i=1}^n x_i} \end{aligned}$$

先验分布 $p \sim U[0, 1]$, 即 $Beta(1, 1)$ 分布, 密度函数 $\pi(p) = 1, 0 < p < 1$ 。

第二步: 确定后验分布。后验分布密度函数为:

$$\begin{aligned} \pi(p|x) &\propto L(p; x)\pi(p) \\ &\propto p^{\sum x_i} (1-p)^{10n - \sum x_i} \cdot 1 \\ &= p^{(\sum x_i + 1) - 1} (1-p)^{(10n - \sum x_i + 1) - 1} \end{aligned}$$

这正是 Beta 分布的核。因此, 后验分布为:

$$p|x \sim Beta \left(\sum_{i=1}^n x_i + 1, 10n - \sum_{i=1}^n x_i + 1 \right)$$

第三步: 求贝叶斯估计。在平方损失函数下, 贝叶斯估计量 T_2 为后验分布的期望。若 $Y \sim Beta(\alpha, \beta)$, 则 $E(Y) = \frac{\alpha}{\alpha + \beta}$ 。此处 $\alpha = \sum x_i + 1, \beta = 10n - \sum x_i + 1$ 。

$$T_2 = E(p|x) = \frac{\sum_{i=1}^n X_i + 1}{10n + 2}$$

(3) 比较 T_1 和 T_2 的优劣

我们将通过比较两个估计量的方差来评价其优劣。

比较估计量 T_1, T_2 , 有: $Var(T_1) = Var(\frac{1}{n}\bar{X}) = \frac{1}{n^2}Var(\bar{X})$

$$Var(T_2) = Var\left(\frac{n\bar{X} + 1}{10n + 2}\right) = \left(\frac{n}{10n + 2}\right)^2 Var(\bar{X}) > Var(T_1)$$

所以, T_1 优于 T_2

问题 37. 设随机变量 X 服从几何分布, 即 $P(X = k) = \theta(1 - \theta)^k, k = 0, 1, 2, \dots$, 其中参数 θ 的先验分布为均匀分布 $U(0, 1)$ 。

(1) 若只对 X 作一次观察, 观察值为 3, 在平方损失函数下求 θ 的 Bayes 估计;

(2) 若对 X 三次观察, 观察值为 2, 3, 5, 在平方损失函数下求 θ 的 Bayes 估计。

【解析】

解题准备: 确定后验分布的一般形式

设总体 X 服从几何分布, 其概率分布列为:

$$P(X = x) = \theta(1 - \theta)^x, \quad x = 0, 1, 2, \dots$$

参数 θ 的先验分布为均匀分布 $U(0, 1)$, 即 $Beta(1, 1)$ 分布, 其密度函数为:

$$\pi(\theta) = 1, \quad 0 < \theta < 1$$

在平方损失函数下, 参数 θ 的贝叶斯估计量 $\hat{\theta}$ 为后验分布的期望 $E(\theta|X)$ 。

(1) 只作一次观察, 观察值 $x = 3$

1 写出似然函数

$$L(\theta; x) = P(X = 3) = \theta(1 - \theta)^3$$

2 求后验分布。根据贝叶斯公式, 后验密度 $\pi(\theta|x)$ 正比于似然函数与先验密度的乘积:

$$\begin{aligned} \pi(\theta|x) &\propto L(\theta; x)\pi(\theta) \\ &= \theta(1 - \theta)^3 \cdot 1 \\ &= \theta^{2-1}(1 - \theta)^{4-1} \end{aligned}$$

观察该式, 它是 $Beta(2, 4)$ 分布的核。因此, 后验分布为 $\theta|x \sim Beta(2, 4)$ 。

3 求贝叶斯估计。后验分布的期望即为贝叶斯估计:

$$\hat{\theta} = E(\theta|x) = \frac{2}{2+4} = \frac{2}{6} = \frac{1}{3}$$

(2) 作三次观察, 观察值 $x_1 = 2, x_2 = 3, x_3 = 5$

1 写出似然函数。样本 $x = (2, 3, 5)$ 的似然函数为:

$$\begin{aligned} L(\theta; x) &= \prod_{i=1}^3 P(X = x_i) \\ &= [\theta(1-\theta)^2] \cdot [\theta(1-\theta)^3] \cdot [\theta(1-\theta)^5] \\ &= \theta^3(1-\theta)^{2+3+5} \\ &= \theta^3(1-\theta)^{10} \end{aligned}$$

2 求后验分布。同样利用贝叶斯公式:

$$\begin{aligned} \pi(\theta|x) &\propto L(\theta; x)\pi(\theta) \\ &= \theta^3(1-\theta)^{10} \cdot 1 \\ &= \theta^{4-1}(1-\theta)^{11-1} \end{aligned}$$

这对应于 $Beta(4, 11)$ 分布的核。因此, 后验分布为 $\theta|x \sim Beta(4, 11)$ 。

3 求贝叶斯估计。计算后验分布的期望:

$$\hat{\theta} = E(\theta|x) = \frac{4}{4+11} = \frac{4}{15}$$

问题 38. 对正态分布 $N(\theta, 1)$ 观察, 获得三个独立观察值 $X_1 = 2, X_2 = 3, X_3 = 4$, 若 θ 的先验分布为 $N(3, 1)$, 求 θ 的 0.95 可信区间。

【解析】

解题思路:

1. 确定模型结构: 这是典型的正态似然函数配合正态先验分布, 属于共轭先验情形。
2. 求解后验分布: 利用正态-正态模型的后验参数更新公式求出 θ 的后验分布 $\theta|x \sim N(\mu_n, \sigma_n^2)$ 。设 X_1, X_2, \dots, X_n 是来自 $N(\mu, \sigma^2)$ 的独立同分布样本, 其中 σ^2 已知。假设参数 μ 的先验分布为正态分布: $\mu \sim N(\mu_0, \tau_0^2)$ 。以下是需要牢记的核心公式:
(1) 后验精度公式, 在贝叶斯统计中, 方差的倒数 $1/\sigma^2$ 称为精度。

$$\frac{1}{\sigma_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

解释: 后验精度 = 先验精度 + 样本精度。这体现了信息的叠加。

(2) 后验均值公式, 后验均值是先验均值和样本均值的加权平均:

$$\mu_n = \frac{\frac{1}{\tau_0^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \mu_0 + \frac{\frac{n}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}} \bar{x}$$

也可以写成更常见的形式: $\mu_n = \sigma_n^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\tau_0^2} \right)$

3. 构造可信区间：基于后验正态分布，利用标准正态分位数确定 95% 等尾可信区间。

第一步：整理样本信息。已知样本观测值为 $x_1 = 2, x_2 = 3, x_3 = 4$ ，样本容量 $n = 3$ 。计算样本均值：

$$\bar{x} = \frac{2 + 3 + 4}{3} = 3$$

总体方差已知： $\sigma^2 = 1$ 。

第二步：确定后验分布。模型设定如下：

- 总体分布： $X \sim N(\theta, \sigma^2) = N(\theta, 1)$
- 先验分布： $\theta \sim N(\mu_0, \tau^2) = N(3, 1)$ ，即 $\mu_0 = 3, \tau^2 = 1$ 。

对于正态均值的贝叶斯推断，后验分布 $\theta|x$ 依然服从正态分布 $N(\mu_n, \sigma_n^2)$ 。利用参数更新公式：

1 计算后验精度（方差的倒数）：

$$\frac{1}{\sigma_n^2} = \frac{n}{\sigma^2} + \frac{1}{\tau^2} = \frac{3}{1} + \frac{1}{1} = 4$$

所以，后验方差 $\sigma_n^2 = \frac{1}{4} = 0.25$ ，后验标准差 $\sigma_n = \sqrt{0.25} = 0.5$ 。

2 计算后验均值：

$$\mu_n = \sigma_n^2 \left(\frac{n\bar{x}}{\sigma^2} + \frac{\mu_0}{\tau^2} \right)$$

代入数值：

$$\mu_n = \frac{1}{4} \left(\frac{3 \times 3}{1} + \frac{3}{1} \right) = \frac{1}{4}(9 + 3) = \frac{12}{4} = 3$$

综上， θ 的后验分布为：

$$\theta|x \sim N(3, 0.5^2)$$

第三步：求 0.95 可信区间。贝叶斯可信区间基于后验分布计算。对于正态分布 $N(\mu_n, \sigma_n^2)$ ，其 $1 - \alpha$ 等尾可信区间为：

$$[\mu_n - z_{\alpha/2}\sigma_n, \mu_n + z_{\alpha/2}\sigma_n]$$

这里 $1 - \alpha = 0.95$ ，即 $\alpha = 0.05$ ， $\alpha/2 = 0.025$ 。查标准正态分布表可知，上侧 0.025 分位数 $z_{0.025} = 1.96$ ，在标准正态分布曲线下，右侧尾部面积恰好等于 0.025 的那个横坐标值是 1.96。

代入数值：

- 下界： $3 - 1.96 \times 0.5 = 3 - 0.98 = 2.02$
- 上界： $3 + 1.96 \times 0.5 = 3 + 0.98 = 3.98$

所以，参数 θ 的 0.95 贝叶斯可信区间为 $[2.02, 3.98]$ 。

问题 39. 设随机变量 X 服从几何分布, 其分布列为 $P(X = x) = \theta(1-\theta)^x, x = 0, 1, 2, \dots$, 其中参数 θ 只能取 $1/4, 2/4$ 和 $3/4$ 三个值, 并以相同概率取这三个值。如今只获得一个观察值 $X = 2$, 要在 $0-1$ 损失函数下寻求 θ 的贝叶斯估计。

【解析】

第一步：整理已知信息。

1. 似然函数：总体 X 服从几何分布, 当观测值 $X = 2$ 时, 似然函数为:

$$P(X = 2|\theta) = \theta(1 - \theta)^2$$

2. 先验分布：参数 θ 的取值空间为 $\Theta = \{\theta_1 = 0.25, \theta_2 = 0.5, \theta_3 = 0.75\}$ 。先验概率为均匀分布：

$$\pi(\theta_1) = \pi(\theta_2) = \pi(\theta_3) = \frac{1}{3}$$

3. 损失函数：采用 $0-1$ 损失函数。在该损失下, 贝叶斯估计量 $\hat{\theta}_B$ 是使后验概率最大的那个 θ 值。

第二步：计算联合概率。

我们需要计算每个 θ_i 对应的联合概率 $P(X = 2, \theta_i) = P(X = 2|\theta_i)\pi(\theta_i)$ 。

1. 当 $\theta = 1/4 = 0.25$ 时:

$$P(X = 2|\theta = 0.25) = 0.25 \times (1 - 0.25)^2 = 0.25 \times 0.75^2 = 0.25 \times 0.5625 = 0.140625$$

联合概率:

$$P(X = 2, \theta = 0.25) = 0.140625 \times \frac{1}{3}$$

2. 当 $\theta = 2/4 = 0.5$ 时:

$$P(X = 2|\theta = 0.5) = 0.5 \times (1 - 0.5)^2 = 0.5 \times 0.5^2 = 0.5 \times 0.25 = 0.125$$

联合概率:

$$P(X = 2, \theta = 0.5) = 0.125 \times \frac{1}{3}$$

3. 当 $\theta = 3/4 = 0.75$ 时:

$$P(X = 2|\theta = 0.75) = 0.75 \times (1 - 0.75)^2 = 0.75 \times 0.25^2 = 0.75 \times 0.0625 = 0.046875$$

联合概率:

$$P(X = 2, \theta = 0.75) = 0.046875 \times \frac{1}{3}$$

第三步：比较后验概率

根据贝叶斯公式, 后验概率 $P(\theta_i|X = 2) = \frac{P(X = 2|\theta_i)\pi(\theta_i)}{\sum P(X = 2|\theta_j)\pi(\theta_j)} \propto P(X = 2|\theta_i)\pi(\theta_i)$ 。

由于先验概率 $\pi(\theta_i)$ 都相同, 因此后验概率的大小正比于似然函数 $P(X = 2|\theta_i)$ 的大小。比较计算出的似然函数值, 显然, $0.140625 > 0.125 > 0.046875$ 。

第四步：得出结论

在 $0-1$ 损失函数下, 贝叶斯估计量是后验概率最大的值。

$$\hat{\theta}_B = \frac{1}{4}$$

1.8 多元统计基础

定义 1.8.1 (p 维正态分布). 设 $X = (X_1, X_2, \dots, X_p)^T$ 为 p 维随机向量。如果对于任意常向量 $\mathbf{a} \in \mathbb{R}^p$, 标量随机变量 $Y = \mathbf{a}^T X = \sum_{i=1}^p a_i X_i$ 都服从一元正态分布 (包括方差为 0 的退化正态分布, 即常数), 则称 X 服从 p 维正态分布。

1.8.1 多元正态分布的基本性质

设 $\mathbf{x} \sim N_p(\mu, \Sigma)$ 。

- \mathbf{x} : 是一个 $p \times 1$ 的列向量, 包含 p 个随机变量, 即 $\mathbf{x} = (X_1, X_2, \dots, X_p)^T$ 。
- μ : 是均值向量, 维度为 $p \times 1$ 。 $\mu = E[\mathbf{x}] = (E[X_1], E[X_2], \dots, E[X_p])^T$
- Σ : 是协方差矩阵, 维度为 $p \times p$, 必须是对称的 (因为 $\sigma_{ij} = \sigma_{ji}$) 且是半正定的。

$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_p^2 \end{pmatrix}$, 对角线元素 σ_i^2 是第 i 个分量 X_i 的方差。非对角线元素 σ_{ij} 是 X_i 与 X_j 的协方差。

- 边缘分布: \mathbf{x} 的任意子向量 (或分量) 仍然服从正态分布。
 - **操作方法**: 直接从 μ 和 Σ 中截取对应的元素即可。例如 $x_1 \sim N(\mu_1, \sigma_{11})$ 。
- 独立性与不相关:
 - 对于正态分布, 不相关 \Leftrightarrow 独立。
 - 若要证明两个分量 (或线性组合) 独立, 只需证明它们的协方差为 0。
- 联合概率密度函数:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\}$$

1.8.2 多元正态分布线性变换的分布

这是计算题的核心。若 $\mathbf{x} \sim N_p(\mu, \Sigma)$, 令 $\mathbf{y} = A\mathbf{x} + \mathbf{b}$, 则 \mathbf{y} 也服从正态分布。必须熟练掌握的三个数字特征公式:

1. 期望:

$$E(A\mathbf{x} + \mathbf{b}) = A\mu + \mathbf{b}$$

2. 方差 (协方差矩阵):

$$\text{Var}(A\mathbf{x} + \mathbf{b}) = A\Sigma A^T$$

3. 两组线性组合的协方差：若 $\mathbf{y}_1 = A\mathbf{x}$, $\mathbf{y}_2 = B\mathbf{x}$, 则：

$$\text{Cov}(\mathbf{y}_1, \mathbf{y}_2) = A\Sigma B^T$$

考点：如果算出来 $A\Sigma B^T = \mathbf{0}$, 则 \mathbf{y}_1 与 \mathbf{y}_2 独立。

4. 协方差运算律： $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + \text{Cov}(X, Y) + \text{Cov}(Y, X)$

$$\text{Cov}(AX, BY) = A\text{Cov}(X, Y)B^T$$

$$\text{Cov}(aX + b, cY + d) = ac\text{Cov}(X, Y), \text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

1.8.3 条件分布与回归函数

这是大题中最容易丢分的地方，公式较繁琐，需死记硬背。

$$\text{设 } \mathbf{x} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right).$$

考点：给定 \mathbf{x}_2 时， \mathbf{x}_1 的条件分布

$$\mathbf{x}_1 | \mathbf{x}_2 \sim N(\mu_{1|2}, \Sigma_{1|2})$$

- 条件均值 (回归函数)：

$$E(\mathbf{x}_1 | \mathbf{x}_2) = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

注：题目若问“求 x_1 对 x_2 的回归函数”，算的就是这个条件期望！

- 条件方差：

$$\text{Var}(\mathbf{x}_1 | \mathbf{x}_2) = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

- 2×2 矩阵求逆：主对调，副变号，除行列式

解题三步走：

1. 分块：明确谁是 \mathbf{x}_1 (未知的)，谁是 \mathbf{x}_2 (已知的/条件的)。
2. 求逆：计算条件变量的方差矩阵 Σ_{22} 的逆矩阵 Σ_{22}^{-1} 。
3. 代入：套用上述两个公式。

1.8.4 练习题

问题 40. 判断题： X 为 p 维正态随机向量的充要条件为：对任一 p 维向量 \mathbf{c} , $\mathbf{c}^T X$ 是一维正态随机变量。(✓)

问题 41. 设 $\mathbf{x} \sim N_3(\mu, \Sigma)$, 其中 $\mu = \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix}$, $\Sigma = \begin{pmatrix} 16 & -4 & 2 \\ -4 & 4 & -1 \\ 2 & -1 & 4 \end{pmatrix}$ 。在给定 $x_1 + 2x_3$ 时, 求 $\begin{pmatrix} x_2 - x_3 \\ x_1 \end{pmatrix}$ 的条件分布。

【解析】

这是一道关于多元正态分布中线性变换及条件分布的典型计算题。

解题思路:

1. 定义新变量: 将题目中涉及的所有线性组合定义为新的随机向量。设 $Y = \begin{pmatrix} x_2 - x_3 \\ x_1 \end{pmatrix}$ 为我们关心的变量, 设 $Z = x_1 + 2x_3$ 为条件变量。

2. 构造联合分布: 将 Y 和 Z 组合成一个新的随机向量 $\mathbf{W} = \begin{pmatrix} Y \\ Z \end{pmatrix} = \begin{pmatrix} x_2 - x_3 \\ x_1 \\ x_1 + 2x_3 \end{pmatrix}$ 。
由于 \mathbf{x} 服从正态分布, \mathbf{W} 作为 \mathbf{x} 的线性变换, 也服从多元正态分布。

3. 计算联合分布的参数: 利用矩阵乘法计算 \mathbf{W} 的均值向量和协方差矩阵。

4. 利用条件分布公式: 对于多元正态分布 $\begin{pmatrix} Y \\ Z \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_Y \\ \mu_Z \end{pmatrix}, \begin{pmatrix} \Sigma_{YY} & \Sigma_{YZ} \\ \Sigma_{ZY} & \Sigma_{ZZ} \end{pmatrix}\right)$, 给定 Z 时 Y 的条件分布 $Y|Z$ 依然是正态分布, 其均值和协方差分别为:

$$E(Y|Z) = \mu_Y + \Sigma_{YZ}\Sigma_{ZZ}^{-1}(Z - \mu_Z), \quad Var(Y|Z) = \Sigma_{YY} - \Sigma_{YZ}\Sigma_{ZZ}^{-1}\Sigma_{ZY}$$

步骤 1: 构造线性变换矩阵

设 $\mathbf{W} = \begin{pmatrix} Y \\ Z \end{pmatrix} = \begin{pmatrix} x_2 - x_3 \\ x_1 \\ x_1 + 2x_3 \end{pmatrix} = A\mathbf{x}$ 。根据定义, 变换矩阵 A 为:

$$A = \begin{pmatrix} 0 & 1 & -1 \\ 1 & 0 & 0 \\ 1 & 0 & 2 \end{pmatrix}$$

其中前两行对应 Y , 第三行对应 Z 。

步骤 2: 计算 \mathbf{W} 的均值向量 $E(\mathbf{W})$

$$E(\mathbf{W}) = A\mu = \begin{pmatrix} 0 & 1 & -1 \\ 1 & 0 & 0 \\ 1 & 0 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ -3 \end{pmatrix}$$

所以:

$$\mu_Y = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mu_Z = -3$$

步骤 3: 计算 \mathbf{W} 的协方差矩阵 $Var(\mathbf{W})$

$$Var(\mathbf{W}) = A\Sigma A^T. \text{ 已知 } \Sigma = \begin{pmatrix} 16 & -4 & 2 \\ -4 & 4 & -1 \\ 2 & -1 & 4 \end{pmatrix}.$$

先计算 ΣA^T :

$$\Sigma A^T = \begin{pmatrix} 16 & -4 & 2 \\ -4 & 4 & -1 \\ 2 & -1 & 4 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ -1 & 0 & 2 \end{pmatrix} = \begin{pmatrix} -6 & 16 & 20 \\ 5 & -4 & -6 \\ -5 & 2 & 10 \end{pmatrix}$$

再计算 $A(\Sigma A^T)$:

$$A\Sigma A^T = \begin{pmatrix} 0 & 1 & -1 \\ 1 & 0 & 0 \\ 1 & 0 & 2 \end{pmatrix} \begin{pmatrix} -6 & 16 & 20 \\ 5 & -4 & -6 \\ -5 & 2 & 10 \end{pmatrix} = \begin{pmatrix} 10 & -6 & -16 \\ -6 & 16 & 20 \\ -16 & 20 & 40 \end{pmatrix}$$

我们将此协方差矩阵分块:

$$Var(\mathbf{W}) = \begin{pmatrix} \Sigma_{YY} & \Sigma_{YZ} \\ \Sigma_{ZY} & \Sigma_{ZZ} \end{pmatrix}$$

其中:

$$\Sigma_{YY} = \begin{pmatrix} 10 & -6 \\ -6 & 16 \end{pmatrix}, \quad \Sigma_{YZ} = \begin{pmatrix} -16 \\ 20 \end{pmatrix}, \quad \Sigma_{ZY} = \begin{pmatrix} -16 & 20 \end{pmatrix}, \quad \Sigma_{ZZ} = 40$$

步骤 4: 计算条件分布的参数

1 条件协方差:

$$\begin{aligned} Var(Y|Z) &= \Sigma_{YY} - \Sigma_{YZ}\Sigma_{ZZ}^{-1}\Sigma_{ZY} \\ &= \begin{pmatrix} 10 & -6 \\ -6 & 16 \end{pmatrix} - \begin{pmatrix} -16 \\ 20 \end{pmatrix} \frac{1}{40} \begin{pmatrix} -16 & 20 \end{pmatrix} \\ &= \begin{pmatrix} 3.6 & 2 \\ 2 & 6 \end{pmatrix} \end{aligned}$$

2 条件均值: 令 z 为给定值 $x_1 + 2x_3$ 。

$$\begin{aligned} E(Y|Z=z) &= \mu_Y + \Sigma_{YZ}\Sigma_{ZZ}^{-1}(z - \mu_Z) \\ &= \begin{pmatrix} 2 \\ 1 \end{pmatrix} + \begin{pmatrix} -16 \\ 20 \end{pmatrix} \frac{1}{40}(z - (-3)) \\ &= \begin{pmatrix} 0.8 - 0.4z \\ 2.5 + 0.5z \end{pmatrix} \end{aligned}$$

结论

在给定 $Z = x_1 + 2x_3$ 的条件下, $Y = \begin{pmatrix} x_2 - x_3 \\ x_1 \end{pmatrix}$ 服从二元正态分布:

$$\begin{pmatrix} x_2 - x_3 \\ x_1 \end{pmatrix} \bigg| (x_1 + 2x_3) \sim N_2 \left(\begin{pmatrix} 0.8 - 0.4(x_1 + 2x_3) \\ 2.5 + 0.5(x_1 + 2x_3) \end{pmatrix}, \begin{pmatrix} 3.6 & 2 \\ 2 & 6 \end{pmatrix} \right)$$

问题 42. 设 $\mathbf{x} = (x_1, x_2, x_3)' \sim N_3(\mu, \Sigma)$, 其中 $\mu = \begin{pmatrix} 10 \\ 4 \\ 7 \end{pmatrix}$, $\Sigma = \begin{pmatrix} 9 & -3 & -3 \\ -3 & 5 & 1 \\ -3 & 1 & 5 \end{pmatrix}$ 。求 x_1 对 $(x_2, x_3)'$ 的回归函数。

【解析】

在多元正态分布中, x_1 对 $(x_2, x_3)'$ 的回归函数定义为条件期望 $E(x_1|x_2, x_3)$ 。对于正态分布而言, 这个回归函数是线性的。

1 标记分块矩阵

我们将随机向量 \mathbf{x} 分为两部分:

$$Y = x_1, \quad \mathbf{Z} = \begin{pmatrix} x_2 \\ x_3 \end{pmatrix}$$

根据题目给出的均值向量 μ 和协方差矩阵 Σ , 我们将它们对应分块:

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} = \begin{pmatrix} 10 \\ 4 \\ 7 \end{pmatrix} \implies \mu_Y = 10, \quad \mu_{\mathbf{Z}} = \begin{pmatrix} 4 \\ 7 \end{pmatrix}$$

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_{33} \end{pmatrix} = \begin{pmatrix} 9 & -3 & -3 \\ -3 & 5 & 1 \\ -3 & 1 & 5 \end{pmatrix}$$

分块协方差矩阵为:

$$\Sigma_{YY} = 9$$

$$\Sigma_{Y\mathbf{Z}} = \begin{pmatrix} -3 & -3 \end{pmatrix}$$

$$\Sigma_{\mathbf{Z}Y} = \begin{pmatrix} -3 \\ -3 \end{pmatrix}$$

$$\Sigma_{\mathbf{Z}\mathbf{Z}} = \begin{pmatrix} 5 & 1 \\ 1 & 5 \end{pmatrix}$$

2 引用回归函数公式

多元正态分布的条件期望公式为：

$$E(Y|\mathbf{Z}) = \mu_Y + \Sigma_{YZ}\Sigma_{ZZ}^{-1}(\mathbf{Z} - \mu_Z)$$

3 计算 Σ_{ZZ} 的逆矩阵

$$\Sigma_{ZZ} = \begin{pmatrix} 5 & 1 \\ 1 & 5 \end{pmatrix}$$

其行列式为：

$$|\Sigma_{ZZ}| = 5 \times 5 - 1 \times 1 = 25 - 1 = 24$$

其逆矩阵为：

$$\Sigma_{ZZ}^{-1} = \frac{1}{24} \begin{pmatrix} 5 & -1 \\ -1 & 5 \end{pmatrix}$$

4 计算回归系数 $\Sigma_{YZ}\Sigma_{ZZ}^{-1}$

$$\begin{aligned} \Sigma_{YZ}\Sigma_{ZZ}^{-1} &= \begin{pmatrix} -3 & -3 \end{pmatrix} \cdot \frac{1}{24} \begin{pmatrix} 5 & -1 \\ -1 & 5 \end{pmatrix} \\ &= \begin{pmatrix} -0.5 & -0.5 \end{pmatrix} \end{aligned}$$

5 代入公式计算回归函数

$$\begin{aligned} E(x_1|x_2, x_3) &= 10 + \begin{pmatrix} -0.5 & -0.5 \end{pmatrix} \begin{pmatrix} x_2 - 4 \\ x_3 - 7 \end{pmatrix} \\ &= 15.5 - 0.5x_2 - 0.5x_3 \end{aligned}$$

结论

x_1 对 $(x_2, x_3)'$ 的回归函数为：

$$x_1 = 15.5 - 0.5x_2 - 0.5x_3$$

问题 43. 设 $\mathbf{x} \sim N_{2p}(\mu, \Sigma)$, 令 $\mathbf{x} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix}$, 其中 \mathbf{x}_1 是 \mathbf{x} 的前 p 个分量, \mathbf{x}_2 是 \mathbf{x} 的后 p 个分量, 同时将 μ 和 Σ 进行相应分块, 记为 $\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$ 和 $\Sigma = \begin{pmatrix} \Sigma_1 & \Sigma_2 \\ \Sigma_2 & \Sigma_1 \end{pmatrix}$ 。

(1) 证明 $\mathbf{x}_1 + \mathbf{x}_2$ 和 $\mathbf{x}_1 - \mathbf{x}_2$ 相互独立；

(2) 求 $\mathbf{x}_1 + \mathbf{x}_2$ 和 $\mathbf{x}_1 - \mathbf{x}_2$ 的分布。

【解析】

前置准备：符号与定义

已知 $\mathbf{x} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{pmatrix} \sim N_{2p}(\mu, \Sigma)$, 其中:

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} = \begin{pmatrix} \Sigma_1 & \Sigma_2 \\ \Sigma_2 & \Sigma_1 \end{pmatrix}$$

定义新的随机向量 \mathbf{y}_1 和 \mathbf{y}_2 :

$$\mathbf{y}_1 = \mathbf{x}_1 + \mathbf{x}_2, \quad \mathbf{y}_2 = \mathbf{x}_1 - \mathbf{x}_2$$

(1) 证明 $\mathbf{x}_1 + \mathbf{x}_2$ 和 $\mathbf{x}_1 - \mathbf{x}_2$ 相互独立

由于 \mathbf{x} 服从多元正态分布, \mathbf{y}_1 和 \mathbf{y}_2 都是 \mathbf{x} 的线性组合, 因此它们联合服从多元正态分布。对于联合正态分布的随机向量, 独立性等价于不相关, 即协方差为 0。

我们需要计算 $\text{Cov}(\mathbf{y}_1, \mathbf{y}_2)$:

$$\begin{aligned} \text{Cov}(\mathbf{y}_1, \mathbf{y}_2) &= \text{Cov}(\mathbf{x}_1 + \mathbf{x}_2, \mathbf{x}_1 - \mathbf{x}_2) \\ &= \text{Cov}(\mathbf{x}_1, \mathbf{x}_1) - \text{Cov}(\mathbf{x}_1, \mathbf{x}_2) + \text{Cov}(\mathbf{x}_2, \mathbf{x}_1) - \text{Cov}(\mathbf{x}_2, \mathbf{x}_2) \end{aligned}$$

代入题目给出的协方差分块:

- $\text{Cov}(\mathbf{x}_1, \mathbf{x}_1) = \Sigma_{11} = \Sigma_1$
- $\text{Cov}(\mathbf{x}_1, \mathbf{x}_2) = \Sigma_{12} = \Sigma_2$
- $\text{Cov}(\mathbf{x}_2, \mathbf{x}_1) = \Sigma_{21} = \Sigma_2$
- $\text{Cov}(\mathbf{x}_2, \mathbf{x}_2) = \Sigma_{22} = \Sigma_1$

代入计算:

$$\begin{aligned} \text{Cov}(\mathbf{y}_1, \mathbf{y}_2) &= \Sigma_1 - \Sigma_2 + \Sigma_2 - \Sigma_1 \\ &= \mathbf{O} \quad (\text{零矩阵}) \end{aligned}$$

因为 \mathbf{y}_1 和 \mathbf{y}_2 联合服从正态分布且协方差矩阵为零, 所以 $\mathbf{x}_1 + \mathbf{x}_2$ 与 $\mathbf{x}_1 - \mathbf{x}_2$ 相互独立。

(2) 求 $\mathbf{x}_1 + \mathbf{x}_2$ 和 $\mathbf{x}_1 - \mathbf{x}_2$ 的分布

由于它们是 \mathbf{x} 的线性变换, 结果必然服从 p 维正态分布 $N_p(\mu', \Sigma')$ 。我们需要分别求出期望向量和方差 (协方差) 矩阵。

1 求 $\mathbf{y}_1 = \mathbf{x}_1 + \mathbf{x}_2$ 的分布

均值:

$$E(\mathbf{y}_1) = E(\mathbf{x}_1) + E(\mathbf{x}_2) = \mu_1 + \mu_2$$

方差:

$$\begin{aligned} \text{Var}(\mathbf{y}_1) &= \text{Cov}(\mathbf{x}_1 + \mathbf{x}_2, \mathbf{x}_1 + \mathbf{x}_2) \\ &= \text{Var}(\mathbf{x}_1) + \text{Cov}(\mathbf{x}_1, \mathbf{x}_2) + \text{Cov}(\mathbf{x}_2, \mathbf{x}_1) + \text{Var}(\mathbf{x}_2) \\ &= \Sigma_1 + \Sigma_2 + \Sigma_2 + \Sigma_1 \\ &= 2(\Sigma_1 + \Sigma_2) \end{aligned}$$

所以:

$$\mathbf{x}_1 + \mathbf{x}_2 \sim N_p(\mu_1 + \mu_2, 2(\Sigma_1 + \Sigma_2))$$

2 求 $\mathbf{y}_2 = \mathbf{x}_1 - \mathbf{x}_2$ 的分布

均值:

$$E(\mathbf{y}_2) = E(\mathbf{x}_1) - E(\mathbf{x}_2) = \mu_1 - \mu_2$$

方差:

$$\begin{aligned} \text{Var}(\mathbf{y}_2) &= \text{Cov}(\mathbf{x}_1 - \mathbf{x}_2, \mathbf{x}_1 - \mathbf{x}_2) \\ &= \text{Var}(\mathbf{x}_1) - \text{Cov}(\mathbf{x}_1, \mathbf{x}_2) - \text{Cov}(\mathbf{x}_2, \mathbf{x}_1) + \text{Var}(\mathbf{x}_2) \\ &= \Sigma_1 - \Sigma_2 - \Sigma_2 + \Sigma_1 \\ &= 2(\Sigma_1 - \Sigma_2) \end{aligned}$$

所以:

$$\mathbf{x}_1 - \mathbf{x}_2 \sim N_p(\mu_1 - \mu_2, 2(\Sigma_1 - \Sigma_2))$$

问题 44. 设 $\mathbf{x} \sim N_3(\mu, \Sigma)$, 其中 $\mu = \begin{pmatrix} 2 \\ -3 \\ 1 \end{pmatrix}$, $\Sigma = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$ 。

(1) 求 $2x_1 - x_2 + 3x_3$ 的分布。

(2) 求常数 a 与 b , 使 x_3 与 $x_3 + ax_1 + bx_2$ 相互独立。

【解析】

解题思路:

1 第一问: 求线性组合 $Y = \mathbf{c}^T \mathbf{x}$ 的分布。由于 \mathbf{x} 是多元正态分布, 其线性组合服从一元正态分布 $N(\mathbf{c}^T \mu, \mathbf{c}^T \Sigma \mathbf{c})$ 。

2 第二问: 利用正态分布的性质, 两变量独立等价于协方差为 0。我们需要构造关于 a 和 b 的方程 $\text{Cov}(x_3, x_3 + ax_1 + bx_2) = 0$, 解方程组即可。

(1) 求 $2x_1 - x_2 + 3x_3$ 的分布

令 $Y = 2x_1 - x_2 + 3x_3$ 。这可以写成向量形式 $Y = \mathbf{c}^T \mathbf{x}$, 其中 $\mathbf{c} = \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix}$ 。由于 $\mathbf{x} \sim N_3(\mu, \Sigma)$, 根据多元正态分布的性质, 线性组合 Y 服从一元正态分布 $N(E(Y), D(Y))$ 。

1 计算期望 $E(Y)$:

$$E(Y) = \mathbf{c}^T \mu = \begin{pmatrix} 2 & -1 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ -3 \\ 1 \end{pmatrix} = 10$$

2 计算方差 $D(Y)$:

$$D(Y) = \mathbf{c}^T \Sigma \mathbf{c} = \begin{pmatrix} 2 & -1 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix} = 29$$

结论: $2x_1 - x_2 + 3x_3 \sim N(10, 29)$ 。

(2) 求常数 a 与 b , 使 x_3 与 $x_3 + ax_1 + bx_2$ 相互独立

设 $Z_1 = x_3$, $Z_2 = x_3 + ax_1 + bx_2$ 。由于 \mathbf{x} 服从多元正态分布, $\mathbf{Z} = (Z_1, Z_2)^T$ 也服从多元正态分布。对于联合正态分布的随机变量, 独立性等价于不相关, 即要求 $\text{Cov}(Z_1, Z_2) = 0$ 。

计算协方差:

$$\begin{aligned} \text{Cov}(Z_1, Z_2) &= \text{Cov}(x_3, x_3 + ax_1 + bx_2) \\ &= \text{Cov}(x_3, x_3) + a\text{Cov}(x_3, x_1) + b\text{Cov}(x_3, x_2) \\ &= \text{Var}(x_3) + a\text{Cov}(x_1, x_3) + b\text{Cov}(x_2, x_3) \end{aligned}$$

根据协方差矩阵 $\Sigma = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$, 我们可以直接读取所需的方差和协方差值:

- $\text{Var}(x_3) = \sigma_{33} = 3$
- $\text{Cov}(x_1, x_3) = \sigma_{13} = 1$
- $\text{Cov}(x_2, x_3) = \sigma_{23} = 2$

将这些值代入协方差公式并令其为 0:

$$3 + a(1) + b(2) = 0$$

即:

$$a + 2b = -3$$

这是一个关于 a 和 b 的不定方程。只要 a, b 满足该线性关系, x_3 与 $x_3 + ax_1 + bx_2$ 就相互独立。例如: 令 $b = 0$, 则 $a = -3$; 或令 $a = 1$, 则 $b = -2$ 。

结论: 常数 a, b 需满足关系式 $a + 2b = -3$ 。

问题 45. 设 $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2(\mu, \Sigma)$, 记 $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$, $\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} \triangleq \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} > 0$ (即 $\sigma_1 > 0, \sigma_2 > 0, |\rho| < 1$)。

(1) 试写出 X 的联合密度函数和边缘密度函数;

(2) 试说明 ρ 的统计意义。

【解析】**(1) 写出 X 的联合密度函数和边缘密度函数****1 联合密度函数**

首先写出二元正态分布的密度函数公式为：

$$f(x_1, x_2) = \frac{1}{2\pi|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu) \right\}$$

设 $X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ ，其均值向量为 $\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ ，协方差矩阵为 $\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$ 。

为了写出密度函数，我们需要计算 Σ 的行列式 $|\Sigma|$ 和逆矩阵 Σ^{-1} 。

计算行列式：

$$|\Sigma| = \sigma_1^2\sigma_2^2 - (\rho\sigma_1\sigma_2)^2 = \sigma_1^2\sigma_2^2(1 - \rho^2)$$

计算逆矩阵：

$$\Sigma^{-1} = \frac{1}{|\Sigma|} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix} = \frac{1}{1 - \rho^2} \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \frac{1}{\sigma_2^2} \end{bmatrix}$$

展开二次型 $(x - \mu)^T \Sigma^{-1}(x - \mu)$ ：令 $Q = (x - \mu)^T \Sigma^{-1}(x - \mu)$ ，其中 $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ 。

$$\begin{aligned} Q &= \frac{1}{1 - \rho^2} \begin{bmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{bmatrix} \begin{bmatrix} \frac{1}{\sigma_1^2} & -\frac{\rho}{\sigma_1\sigma_2} \\ -\frac{\rho}{\sigma_1\sigma_2} & \frac{1}{\sigma_2^2} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= \frac{1}{1 - \rho^2} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \end{aligned}$$

代入上述结果得：

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1 - \rho^2}} \exp \left\{ -\frac{1}{2(1 - \rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\}$$

其中 $-\infty < x_1, x_2 < +\infty$ 。

2 边缘密度函数

根据多元正态分布的性质，若 $X \sim N_2(\mu, \Sigma)$ ，则其任意分量（或子向量）也服从正态分布，其均值和方差对应于 μ 和 Σ 中的相应元素。

X_1 的边缘分布： $X_1 \sim N(\mu_1, \sigma_{11}) = N(\mu_1, \sigma_1^2)$ 。其边缘密度函数为：

$$f_1(x_1) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right\}, \quad -\infty < x_1 < +\infty$$

X_2 的边缘分布： $X_2 \sim N(\mu_2, \sigma_{22}) = N(\mu_2, \sigma_2^2)$ 。其边缘密度函数为：

$$f_2(x_2) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right\}, \quad -\infty < x_2 < +\infty$$

(2) 说明 ρ 的统计意义

参数 ρ 称为相关系数。

1. 定义：从协方差矩阵的形式 $\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$ 可以看出, $\text{Cov}(X_1, X_2) = \sigma_{12} = \rho\sigma_1\sigma_2$ 。因此, $\rho = \frac{\text{Cov}(X_1, X_2)}{\sqrt{\text{Var}(X_1)}\sqrt{\text{Var}(X_2)}}$ 。

2. 统计意义： ρ 刻画了随机变量 X_1 和 X_2 之间线性相关关系的密切程度和方向。

- 正负性：

- 若 $\rho > 0$, 表示 X_1 与 X_2 正相关 (变化趋势相同);

- 若 $\rho < 0$, 表示 X_1 与 X_2 负相关 (变化趋势相反)。

- 程度 (大小):

- $|\rho|$ 越接近 1, 表示 X_1 与 X_2 的线性关系越强。

- $|\rho| = 1$ 时, 表示 X_1 与 X_2 存在严格的线性关系 ($X_2 = aX_1 + b$, 概率为 1)。

- $\rho = 0$ 时, 表示 X_1 与 X_2 不相关 (无线性关系)。特别地, 在正态分布中, $\rho = 0$ 等价于 X_1 与 X_2 相互独立。

Chapter 2

期末模拟卷

一、判断题（每题 2 分，共 8 分）

(1) 对于总体分布族 P_θ ，已知 $T = T(\mathbf{X})$ 是参数 θ 的充分统计量，又 $S(\mathbf{X}) = G(T(\mathbf{X}))$ ，且函数 $G(T)$ 是可逆的，则 $S(\mathbf{X})$ 也是参数 θ 的充分统计量。()

【解析】

正确 (✓)

解析：根据充分统计量的性质，如果 T 是充分统计量，且 $S = G(T)$ 是一一映射（即 G 可逆），则 S 也是充分统计量。这是因为样本 X 的条件分布 $P(X|S) = P(X|G(T))$ ，由于 S 和 T 包含的信息量完全相同（可以互相推导），给定 T 已知等价于给定 S 已知，故条件分布不依赖于 θ 。

(2) 设 $\hat{\theta}$ 是 θ 的无偏估计，且有 $D(\hat{\theta}) > 0$ ，则 $\hat{\theta}^2$ 是 θ^2 的无偏估计。()

【解析】

错误 (×)

解析：根据方差的定义 $D(\hat{\theta}) = E(\hat{\theta}^2) - [E(\hat{\theta})]^2$ 。因为 $\hat{\theta}$ 是 θ 的无偏估计，所以 $E(\hat{\theta}) = \theta$ 。故 $E(\hat{\theta}^2) = D(\hat{\theta}) + \theta^2$ 。题目已知 $D(\hat{\theta}) > 0$ ，所以 $E(\hat{\theta}^2) > \theta^2$ 。这意味着 $\hat{\theta}^2$ 是 θ^2 的有偏估计（且为高估）。

(3) 在贝叶斯估计中，随着样本数据量的增加，先验的影响力会越来越小。()

【解析】

正确 (✓)

解析：贝叶斯后验分布由先验分布和似然函数共同决定。随着样本量 $n \rightarrow \infty$ ，似然函数在对数似然函数中占据主导地位（其权重与 n 成正比），而先验分布通常是固定的常数项或相对于 n 可以忽略。因此，数据越多，估计结果越依赖于数据本身，先验的影响逐渐减弱。

(4) \mathbf{X} 为 p 维正态随机向量的充要条件为：对任一 p 维向量 \mathbf{c} ， $\mathbf{c}^T \mathbf{X}$ 是一维正态随机变量。()

【解析】

正确(✓)

解析: 这是多维正态分布的定义之一。如果一个随机向量的任意线性组合都服从一维正态分布, 则该随机向量服从多维正态分布。

二、填空题 (每题 4 分, 共 16 分)

(1) 设 x_1, x_2, \dots, x_n 是来自均匀分布 $U(\theta, 2\theta)$ ($\theta > 0$) 总体 X 的样本, 那么 $T(x_1, x_2, \dots, x_n) =$ _____ 是参数 θ 的充分统计量。

【解析】

$(x_{(1)}, x_{(n)})$

解析: 总体密度函数为 $f(x; \theta) = \frac{1}{\theta} I_{\{\theta \leq x \leq 2\theta\}}$ 。似然函数为:

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} I_{\{\theta \leq x_i \leq 2\theta\}} = \frac{1}{\theta^n} I_{\{\theta \leq x_{(1)}\}} \cdot I_{\{x_{(n)} \leq 2\theta\}}$$

根据因子分解定理, 似然函数依赖于样本仅通过 $(x_{(1)}, x_{(n)})$, 因此充分统计量是 $(x_{(1)}, x_{(n)})$ (即最小次序统计量和最大次序统计量)。

(2) 设总体 X 的概率密度为 $f(x, \theta) = \begin{cases} \frac{1}{\theta} x^{\frac{1-\theta}{\theta}}, & 0 < x < 1 \\ 0, & \text{其它} \end{cases}, (\theta > 0), x_1, x_2, \dots, x_n$

为来自总体 X 的样本值, 则参数 θ 的极大似然估计为 _____。

【解析】

$-\frac{1}{n} \sum_{i=1}^n \ln x_i$ (或 $-\overline{\ln x}$)

解析: 似然函数为:

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} x_i^{\frac{1}{\theta}-1} = \theta^{-n} \left(\prod_{i=1}^n x_i \right)^{\frac{1}{\theta}-1}$$

取对数似然函数:

$$\ln L(\theta) = -n \ln \theta + \left(\frac{1}{\theta} - 1 \right) \sum_{i=1}^n \ln x_i$$

对 θ 求导并令其为 0:

$$\frac{d \ln L}{d \theta} = -\frac{n}{\theta} - \frac{1}{\theta^2} \sum_{i=1}^n \ln x_i = 0$$

解得:

$$-\frac{n}{\theta} = \frac{1}{\theta^2} \sum_{i=1}^n \ln x_i \implies \hat{\theta} = -\frac{1}{n} \sum_{i=1}^n \ln x_i$$

由于 $0 < x_i < 1$, $\ln x_i < 0$, 故 $\hat{\theta} > 0$ 。

(3) 设随机变量 X 服从几何分布, 其分布列为 $P(X = x) = \theta(1-\theta)^x, x = 0, 1, 2, \dots$, 其中参数 θ 只能取 $\frac{1}{4}, \frac{1}{2}, \frac{3}{4}$ 三个值, 并以相同概率取这三个值。如今只能获得一个观察值 $X = 2$, 求后验概率分布 $P(\theta|X = 2)$ 的期望 $E(\theta|X = 2) =$ _____。

【解析】**第一步：确定先验分布**

根据题意，参数 θ 是离散型随机变量，其可能的取值为 $\Theta = \{\theta_1, \theta_2, \theta_3\} = \{\frac{1}{4}, \frac{1}{2}, \frac{3}{4}\}$ 。

由于 θ 以相同概率取这三个值，故其先验分布列为： $P(\theta = \theta_i) = \frac{1}{3}, i = 1, 2, 3$

第二步：计算似然函数

已知样本观测值为 $X = 2$ 。对于给定的 θ ，样本的条件概率为： $P(X = 2|\theta) = \theta(1 - \theta)^2$ ，分别计算 θ 取不同值时的似然：

- 当 $\theta = \frac{1}{4}$ 时， $P(X = 2|\theta = \frac{1}{4}) = \frac{1}{4} \times (1 - \frac{1}{4})^2 = \frac{1}{4} \times \frac{9}{16} = \frac{9}{64}$
- 当 $\theta = \frac{1}{2}$ 时， $P(X = 2|\theta = \frac{1}{2}) = \frac{1}{2} \times (1 - \frac{1}{2})^2 = \frac{1}{2} \times \frac{1}{4} = \frac{1}{8} = \frac{8}{64}$
- 当 $\theta = \frac{3}{4}$ 时， $P(X = 2|\theta = \frac{3}{4}) = \frac{3}{4} \times (1 - \frac{3}{4})^2 = \frac{3}{4} \times \frac{1}{16} = \frac{3}{64}$

第三步：计算全概率

根据全概率公式，观测到 $X = 2$ 的边缘概率为：

$$P(X = 2) = \sum_{i=1}^3 P(X = 2|\theta_i)P(\theta_i) = \left(\frac{9}{64} \times \frac{1}{3}\right) + \left(\frac{8}{64} \times \frac{1}{3}\right) + \left(\frac{3}{64} \times \frac{1}{3}\right) = \frac{5}{48}$$

第四步：求后验概率分布

根据贝叶斯公式 $P(\theta_i|X = 2) = \frac{P(X = 2|\theta_i)P(\theta_i)}{P(X = 2)}$ ：

- $P(\theta = \frac{1}{4}|X = 2) = \frac{\frac{9}{64} \times \frac{1}{3}}{\frac{5}{48}} = \frac{9/192}{20/192} = \frac{9}{20}$
- $P(\theta = \frac{1}{2}|X = 2) = \frac{\frac{8}{64} \times \frac{1}{3}}{\frac{5}{48}} = \frac{8/192}{20/192} = \frac{8}{20}$
- $P(\theta = \frac{3}{4}|X = 2) = \frac{\frac{3}{64} \times \frac{1}{3}}{\frac{5}{48}} = \frac{3/192}{20/192} = \frac{3}{20}$

第五步：计算后验期望

后验期望定义为 θ 在后验分布下的均值： $E(\theta|X = 2) = \sum_{i=1}^3 \theta_i P(\theta_i|X = 2)$
 $E(\theta|X = 2) = \left(\frac{1}{4} \times \frac{9}{20}\right) + \left(\frac{1}{2} \times \frac{8}{20}\right) + \left(\frac{3}{4} \times \frac{3}{20}\right) = \frac{17}{40} = 0.425$

(4) 某一产品有两种品牌，请用户进行评判其优劣，现选了 8 个用户，对这两种品牌的产品分别评分，结果如下：符号秩和检验用的统计量是 $W^+ =$ _____。

用户 i	1	2	3	4	5	6	7	8
品牌 X	55	32	43	48	45	60	50	45
品牌 Y	45	37	41	50	46	54	52	47

符号秩检验标准解题四步法

步骤 1: 计算配对差值。对每对数据计算差值 $d_i = X_i - Y_i$, 剔除 $d_i = 0$ 的样本。

步骤 2: 编秩并处理结。

按 $|d_i|$ 从小到大排序。对相同绝对值的“结”取平均秩。给秩赋予原差值的正负号, 得到符号秩。

步骤 3: 计算检验统计量。

正秩和 W^+ : 所有正符号秩的和。负秩和 W^- : 所有负符号秩绝对值的和。性质:
 $W^+ + W^- = \frac{n(n+1)}{2}$ (n 为非零差值的样本量)。

步骤 4: 决策规则

小样本 ($n \leq 50$): 查 Wilcoxon 符号秩检验界值表, 若 W^+ 位于界值范围内则不拒绝 H_0 , 否则拒绝。

大样本 ($n > 50$): 使用正态近似 $Z = \frac{|W^+ - \frac{n(n+1)}{4}| - 0.5}{\sqrt{\frac{n(n+1)(2n+1)}{24} - \frac{\sum(t_j^3 - t_j)}{48}}}$, 其中 t_j 为第 j 个结的相同数据个数

【解析】

步骤 1: 构造秩表并计算平均秩

首先, 对每对数据计算差值 $d_i = X_i - Y_i$, 剔除所有 $d_i = 0$ 的样本。将绝对值 $|d_i|$ 从小到大排序, 对存在相同绝对值的“结”计算平均秩, 最终得到完整秩表如下:

用户 i	X_i	Y_i	d_i	$ d_i $	秩 (平均秩)	符号秩
5	45	46	-1	1	1	-1
3	43	41	2	2	3.5	+3.5
4	48	50	-2	2	3.5	-3.5
7	50	52	-2	2	3.5	-3.5
8	45	47	-2	2	3.5	-3.5
2	32	37	-5	5	6	-6
6	60	54	6	6	7	+7
1	55	45	10	10	8	+8

步骤 2: 计算正秩和 W^+ , W^+ 为所有正符号秩的和:

$$W^+ = 8 + 3.5 + 7 = 18.5$$

扩展: 确定显著性水平 α 。本题属于配对样本的符号秩和检验, 检验目的是判断两种品牌评分是否存在显著差异:

H_0 : 两种品牌评分无差异, 即差值的中位数 $M_d = 0$, H_1 : 两种品牌评分存在差异, 即 $M_d \neq 0$ (双侧检验)

决策规则: 若 $W_{\alpha/2}(n) < W^+ < \frac{n(n+1)}{2} - W_{\alpha/2}(n)$, 则接受 H_0 , n 为非零差值的个数

三、计算题（每题 12 分，共 36 分）

(1) 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(0, \sigma^2)$ 的简单样本，①求参数 σ^2 的一致最小方差无偏估计 $\hat{\sigma}^2$ ；②样本 x_1, x_2, \dots, x_n 所包含的参数 σ^2 的 Fisher 信息量；③证明 $\hat{\sigma}^2$ 是参数 σ^2 的有效估计。（12 分）

【解析】

(1) 求 σ^2 的 UMVUE

第一步：找充分完备统计量

样本的联合概率密度函数为：

$$f(x_1, \dots, x_n; \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x_i^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_{i=1}^n x_i^2}{2\sigma^2}\right)$$

根据因子分解定理，令 $T = \sum_{i=1}^n x_i^2$ ，则联合密度可写为 $g(T, \sigma^2)h(\mathbf{x})$ 的形式。因此， $T = \sum_{i=1}^n x_i^2$ 是 σ^2 的充分统计量。由于该分布属于指数型分布族，且参数空间包含内点，故 T 是完备充分统计量。

第二步：构造无偏估计

已知 $E[x_i] = 0$ ， $Var(x_i) = \sigma^2$ ，则 $E[x_i^2] = Var(x_i) + (E[x_i])^2 = \sigma^2$ 。考虑统计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ ，其期望为：

$$E[\hat{\sigma}^2] = E\left[\frac{1}{n} \sum_{i=1}^n x_i^2\right] = \frac{1}{n} \sum_{i=1}^n E[x_i^2] = \frac{1}{n} \cdot n\sigma^2 = \sigma^2$$

故 $\hat{\sigma}^2$ 是 σ^2 的无偏估计。

第三步：结论

根据 Lehmann-Scheffé 定理，由于 $\hat{\sigma}^2$ 是完备充分统计量 T 的函数且是无偏的，故 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ 是 σ^2 的 UMVUE。

(2) 计算 Fisher 信息量

设总体密度函数为 $f(x; \theta)$ ，其中 $\theta = \sigma^2$ 。单样本的 Fisher 信息量定义为：

$$I(\theta) = E\left[\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2\right]$$

在满足正则条件（通常默认满足）时，通常使用二阶导数形式计算更为简便：

$$I(\theta) = -E\left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2}\right]$$

对于容量为 n 的独立同分布样本，样本全信息量为： $I_n(\theta) = nI(\theta)$

设单个观测值的对数似然函数为 $l(\sigma^2; x) = \ln f(x; \sigma^2)$ 。令 $\theta = \sigma^2$ ：

$$l(\theta; x) = -\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln \theta - \frac{x^2}{2\theta}$$

对 θ 求一阶导数:

$$\frac{\partial l}{\partial \theta} = -\frac{1}{2\theta} + \frac{x^2}{2\theta^2}$$

对 θ 求二阶导数:

$$\frac{\partial^2 l}{\partial \theta^2} = \frac{1}{2\theta^2} - \frac{x^2}{\theta^3}$$

单个样本的 Fisher 信息量为:

$$I(\theta) = -E \left[\frac{\partial^2 l}{\partial \theta^2} \right] = - \left(\frac{1}{2\theta^2} - \frac{E[x^2]}{\theta^3} \right) = - \left(\frac{1}{2\theta^2} - \frac{\theta}{\theta^3} \right) = \frac{1}{2\theta^2} = \frac{1}{2\sigma^4}$$

由于样本独立同分布, 样本全信息量为: $I_n(\sigma^2) = nI(\sigma^2) = \frac{n}{2\sigma^4}$

(3) 证明有效性

第 0 步: 陈述 Cramer-Rao 不等式 (正式定义)

设 x_1, x_2, \dots, x_n 是来自总体 $f(x; \theta)$ 的样本, $\hat{\theta}$ 是参数 $g(\theta)$ 的一个无偏估计量。在满足正则性条件下, $\hat{\theta}$ 的方差满足:

$$\text{Var}(\hat{\theta}) \geq \frac{[g'(\theta)]^2}{I_n(\theta)}$$

其中 $I_n(\theta)$ 为样本全信息量。此下界称为 Cramer-Rao 下界 (CRLB)。若一个无偏估计量的方差等于该下界, 则称该估计量为 $g(\theta)$ 的**有效估计**。

第一步: 计算 Cramer-Rao 下界

在本题中, 待估参数为 $\theta = \sigma^2$, 待估函数为 $g(\theta) = \theta$ 。因此, $g'(\theta) = \frac{d(\sigma^2)}{d(\sigma^2)} = 1$ 。

由第 (2) 问知 $I_n(\sigma^2) = \frac{n}{2\sigma^4}$, 则 CRLB 为: $CRLB = \frac{1}{I_n(\sigma^2)} = \frac{2\sigma^4}{n}$

第二步: 计算估计量的方差

由于 $x_i \sim N(0, \sigma^2)$, 则 $\frac{x_i}{\sigma} \sim N(0, 1)$, 从而 $\frac{x_i^2}{\sigma^2} \sim \chi^2(1)$ 。根据卡方分布的可加性, $\frac{\sum x_i^2}{\sigma^2} \sim \chi^2(n)$ 。已知 $\chi^2(n)$ 分布的方差为 $2n$, 则:

$$\text{Var} \left(\frac{\sum x_i^2}{\sigma^2} \right) = 2n \implies \frac{1}{\sigma^4} \text{Var} \left(\sum x_i^2 \right) = 2n \implies \text{Var} \left(\sum x_i^2 \right) = 2n\sigma^4$$

因此, $\hat{\sigma}^2$ 的方差为:

$$\text{Var}(\hat{\sigma}^2) = \text{Var} \left(\frac{1}{n} \sum x_i^2 \right) = \frac{1}{n^2} \text{Var} \left(\sum x_i^2 \right) = \frac{2n\sigma^4}{n^2} = \frac{2\sigma^4}{n}$$

结论:

因为 $\text{Var}(\hat{\sigma}^2) = CRLB$, 即该无偏估计量的方差达到了 Cramer-Rao 下界, 所以 $\hat{\sigma}^2$ 是 σ^2 的**有效估计**。

(2) 设 x_1, x_2, \dots, x_n 是来自正态总体 $N(0, \sigma^2)$ 的简单样本, 在显著性水平 α 下, ① 给出下面假设检验问题的似然比检验; ② 给出该似然比检验的势函数 $g(\sigma^2)$; ③ 判断该检验是否为无偏检验。

$$H_0: \sigma^2 \leq \sigma_0^2; \quad H_1: \sigma^2 > \sigma_0^2$$

对于自由度为 n 的卡方分布（记为 $\chi^2(n)$ ），其概率密度函数曲线下的总面积为 1。上 α 分位数，通常记为 $\chi_\alpha^2(n)$ ，是指满足以下条件的数值：在该数值右侧（即大于该数值）的区域面积（概率）恰好等于 α 。

用数学公式表示，如果随机变量 $X \sim \chi^2(n)$ ，那么 $\chi_\alpha^2(n)$ 满足： $P(X > \chi_\alpha^2(n)) = \alpha$ 或者用累积分布函数 $F(x)$ 表示（即左侧面积）： $P(X \leq \chi_\alpha^2(n)) = 1 - \alpha$

【解析】

(1) 似然比检验

基础定义与公式：

似然比检验统计量定义为：

$$\lambda(\mathbf{x}) = \frac{\sup_{\sigma^2 \in \Theta_0} L(\sigma^2)}{\sup_{\sigma^2 \in \Theta} L(\sigma^2)}$$

其中 $\Theta_0 = \{\sigma^2 : \sigma^2 \leq \sigma_0^2\}$ ， $\Theta = \{\sigma^2 : \sigma^2 > 0\}$ 。拒绝域的形式为 $\{\lambda(\mathbf{x}) \leq c\}$ ， c 为常数，且 $0 < c < 1$ 。

第一步：写出似然函数并求极大似然估计

似然函数为： $L(\sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)$

由于对数函数是单调递增函数，似然函数 $L(\sigma^2)$ 和对数似然函数 $l(\sigma^2) = \ln L(\sigma^2)$ 的单调性完全一致，因此我们先计算对数似然：

$$\begin{aligned} l(\sigma^2) &= \ln[(2\pi\sigma^2)^{-n/2}] + \ln\left[\exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)\right] \\ &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{\sum x_i^2}{2\sigma^2} \end{aligned}$$

令 $t = \sigma^2$ ，其中 $t > 0$ ，则对数似然函数变为：

$$l(t) = C - \frac{n}{2} \ln t - \frac{S}{2t}$$

其中 $C = -\frac{n}{2} \ln(2\pi)$ 是常数， $S = \sum x_i^2$ 是样本平方和（非负）。对 $l(t)$ 求一阶导数：

$$l'(t) = -\frac{n}{2t} + \frac{S}{2t^2} = \frac{S - nt}{2t^2}$$

当 $t < \frac{S}{n}$ 时： $S - nt > 0$ ， $l'(t) > 0$ ，因此 $l(t)$ 单调递增，对应 $L(\sigma^2)$ 单调递增；

当 $t = \frac{S}{n}$ 时： $l'(t) = 0$ ，达到极大值点；

当 $t > \frac{S}{n}$ 时： $S - nt < 0$ ， $l'(t) < 0$ ，因此 $l(t)$ 单调递减，对应 $L(\sigma^2)$ 单调递减。

全参数空间 Θ 上的极大似然估计为 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$ 。 $L(\sigma^2)$ 在 $(0, \hat{\sigma}^2)$ 上单调递增，在 $(\hat{\sigma}^2, +\infty)$ 上单调递减。

第二步：计算分子与分母的极大值

- 分母（全空间最大值）： $\sup_{\sigma^2 \in \Theta} L(\sigma^2) = L(\hat{\sigma}^2)$ 。

• 分子 (H_0 空间最大值): $H_0: \sigma^2 \leq \sigma_0^2$ 。

- 若 $\hat{\sigma}^2 \leq \sigma_0^2$, 则 $\hat{\sigma}^2 \in \Theta_0$, 此时最大值在 $\hat{\sigma}^2$ 处取得, 即 $\sup_{\Theta_0} L = L(\hat{\sigma}^2)$ 。
- 若 $\hat{\sigma}^2 > \sigma_0^2$, 由于 $L(\sigma^2)$ 在 $\hat{\sigma}^2$ 左侧单调递增, 故在原假设区间 $(0, \sigma_0^2]$ 上的最大值在右边界 σ_0^2 处取得, 即 $\sup_{\Theta_0} L = L(\sigma_0^2)$ 。

第四步: 构造似然比统计量

$$\lambda(x) = \begin{cases} \frac{L(\hat{\sigma}^2)}{L(\sigma_0^2)} = 1, & \hat{\sigma}^2 \leq \sigma_0^2 \\ \frac{L(\sigma_0^2)}{L(\hat{\sigma}^2)}, & \hat{\sigma}^2 > \sigma_0^2 \end{cases}$$

拒绝域的形式为 $\lambda(x) \leq c < 1$, 这等价于只考虑 $\hat{\sigma}^2 > \sigma_0^2$ 的情况。在该范围内, $\lambda(x)$ 是关于 $\hat{\sigma}^2$ 的单调减函数 (因为 $\hat{\sigma}^2$ 越偏离 σ_0^2 , 似然比越小)。因此, $\lambda(x) \leq c$ 等价于 $\hat{\sigma}^2 \geq k$ 。即拒绝域形式为: $W = \{\sum_{i=1}^n x_i^2 \geq C\}$

第五步: 确定临界值

在 H_0 的边界 $\sigma^2 = \sigma_0^2$ 处, 统计量 $\frac{\sum x_i^2}{\sigma_0^2} \sim \chi^2(n)$ 。

根据显著性水平 α 确定临界值:

$$P_{\sigma_0^2} \left(\sum_{i=1}^n x_i^2 \geq C \right) = P \left(\frac{\sum x_i^2}{\sigma_0^2} \geq \frac{C}{\sigma_0^2} \right) = \alpha$$

令 $\frac{C}{\sigma_0^2} = \chi_\alpha^2(n)$, $\chi_\alpha^2(n)$ 为自由度为 n 的卡方分布的上 α 分位数。解得 $C = \sigma_0^2 \chi_\alpha^2(n)$ 。

结论: 该检验的拒绝域为 $W = \{(x_1, \dots, x_n) : \sum_{i=1}^n x_i^2 > \sigma_0^2 \chi_\alpha^2(n)\}$ 。

(2) 势函数

基础定义与公式:

势函数 $g(\sigma^2)$ 定义为在参数为 σ^2 时拒绝原假设 H_0 的概率, 也就是样本落入拒绝域的概率: $g(\sigma^2) = P_{\sigma^2}(\mathbf{X} \in W)$

具体推导:

$$g(\sigma^2) = P_{\sigma^2}(\sum_{i=1}^n x_i^2 > \sigma_0^2 \chi_\alpha^2(n))$$

为了计算该概率, 我们需要将不等式左边标准化为服从 $\chi^2(n)$ 的变量。不等式两边同时除以真实的参数 σ^2 :

$$g(\sigma^2) = P_{\sigma^2} \left(\frac{\sum x_i^2}{\sigma^2} > \frac{\sigma_0^2}{\sigma^2} \chi_\alpha^2(n) \right)$$

已知 $Y = \frac{\sum x_i^2}{\sigma^2} \sim \chi^2(n)$, 设 $F_n(y)$ 为 $\chi^2(n)$ 分布的累积分布函数, 则: $g(\sigma^2) = 1 - F_n \left(\frac{\sigma_0^2}{\sigma^2} \chi_\alpha^2(n) \right)$

(3) 无偏检验的判断

基础定义与公式: 对于显著性水平为 α 的检验, 如果其势函数 $g(\sigma^2)$ 满足:

- $\forall \sigma^2 \in \Theta_0, \quad g(\sigma^2) \leq \alpha$
- $\forall \sigma^2 \in \Theta_1, \quad g(\sigma^2) \geq \alpha$

则称该检验是无偏检验。

证明过程：

考察势函数 $g(\sigma^2) = P\left(Y > \frac{\sigma_0^2}{\sigma^2} \chi_\alpha^2(n)\right)$, 其中 $Y \sim \chi^2(n)$ 。

- 当 σ^2 增加时, 比值 $\frac{\sigma_0^2}{\sigma^2} \chi_\alpha^2(n)$ 单调递减。
- 对于卡方分布, 下限越小, 右侧尾部面积 (概率) 越大。
- 因此, $g(\sigma^2)$ 是关于 σ^2 的单调递增函数。

验证边界条件：当 $\sigma^2 = \sigma_0^2$ 时, $g(\sigma_0^2) = P\left(Y > \frac{\sigma_0^2}{\sigma_0^2} \chi_\alpha^2(n)\right) = P(Y > \chi_\alpha^2(n)) = \alpha$

结合单调性得出结论：

- 对于 $H_0: \sigma^2 \leq \sigma_0^2$, 有 $g(\sigma^2) \leq g(\sigma_0^2) = \alpha$
- 对于 $H_1: \sigma^2 > \sigma_0^2$, 有 $g(\sigma^2) > g(\sigma_0^2) = \alpha$

综上所述, 该检验是无偏检验。

(3) 设 $\mathbf{x} \sim N_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 其中 $\boldsymbol{\mu} = \begin{pmatrix} 2 \\ -3 \\ 1 \end{pmatrix}$, $\boldsymbol{\Sigma} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix}$ 。① 求 $2x_1 - x_2 + 3x_3$ 的

分布; ② 求常数 a 与 b , 使 x_3 与 $x_3 + ax_1 + bx_2$ 相互独立。(12 分)

【解析】

(1) 求 $Y = 2x_1 - x_2 + 3x_3$ 的分布

基础定理：若 $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 令 $Y = \mathbf{c}^T \mathbf{x}$ (其中 \mathbf{c} 为常数向量), 则 Y 服从一元正态分布 $N(\mathbf{c}^T \boldsymbol{\mu}, \mathbf{c}^T \boldsymbol{\Sigma} \mathbf{c})$ 。在本题中, 系数向量 $\mathbf{c} = \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix}$ 。

第一步：计算期望 $E[Y]$

$$E[Y] = \mathbf{c}^T \boldsymbol{\mu} = 2E[x_1] - 1E[x_2] + 3E[x_3]$$

$$\text{代入 } \boldsymbol{\mu} = (2, -3, 1)^T: E[Y] = 2(2) - 1(-3) + 3(1) = 4 + 3 + 3 = 10$$

第二步：计算方差 $Var(Y)$

方差公式为 $Var(Y) = \mathbf{c}^T \boldsymbol{\Sigma} \mathbf{c}$ 。

$$\text{我们可以先计算 } \boldsymbol{\Sigma} \mathbf{c}: \boldsymbol{\Sigma} \mathbf{c} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix} = \begin{pmatrix} 1(2) + 1(-1) + 1(3) \\ 1(2) + 2(-1) + 2(3) \\ 1(2) + 2(-1) + 3(3) \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \\ 9 \end{pmatrix}$$

再计算 $\mathbf{c}^T(\Sigma\mathbf{c})$: $Var(Y) = \begin{pmatrix} 2 & -1 & 3 \end{pmatrix} \begin{pmatrix} 4 \\ 6 \\ 9 \end{pmatrix} = 2(4) + (-1)(6) + 3(9) = 8 - 6 + 27 = 29$

结论: $2x_1 - x_2 + 3x_3 \sim N(10, 29)$

(2) 求常数 a, b 使变量独立

基础定理:

对于多元正态分布, 两个分量 (或其线性组合) 相互独立的充要条件是它们的协方差为 0。令 $U = x_3$, $V = x_3 + ax_1 + bx_2$ 。我们需要满足 $Cov(U, V) = 0$ 。

计算协方差:

利用协方差的线性性质展开:

$$\begin{aligned} Cov(x_3, x_3 + ax_1 + bx_2) &= Cov(x_3, x_3) + aCov(x_3, x_1) + bCov(x_3, x_2) \\ &= Var(x_3) + aCov(x_1, x_3) + bCov(x_2, x_3) \end{aligned}$$

从协方差矩阵 Σ 中读取对应数值:

- $Var(x_3) = \sigma_{33} = 3$
- $Cov(x_1, x_3) = \sigma_{13} = 1$
- $Cov(x_2, x_3) = \sigma_{23} = 2$

代入方程: $3 + a(1) + b(2) = 0$ 即: $a + 2b = -3$

结论:

只要常数 a, b 满足关系式 $a + 2b = -3$, 变量 x_3 与 $x_3 + ax_1 + bx_2$ 即相互独立。

助教笔记: 易错点提醒

- 矩阵乘法的顺序: 在计算方差 $Var(Y) = \mathbf{c}^T \Sigma \mathbf{c}$ 时, 建议先算右边的矩阵向量乘法 $\Sigma \mathbf{c}$, 得到一个列向量后, 再与左边的行向量 \mathbf{c}^T 相乘。这样计算量最小且不易出错。
- 协方差矩阵的读取: Σ 是对称矩阵, $\Sigma_{ij} = Cov(x_i, x_j)$ 。主对角线是方差: $Var(x_1) = 1, Var(x_2) = 2, Var(x_3) = 3$ 。非对角线是协方差: $Cov(x_1, x_3)$ 对应第一行第三列的元素, 即 1。